ชุดคำสั่งตัดคำภาษาไทยใน LuaLaTeX

ภูริพัฒน์ ถัมภ์บรรฑุ

31 ตุลาคม พ.ศ. 2569

บทคัดย่อ

ชุดคำสั่งนี้ สร้างมาเพื่อตัดคำภาษาไทยใน LuaLaTeX โดยใช้ขั้นตอนวิธี `newmm` จากโปรแกรม PyThaiNLP (Phattiyaphaibun et al., 2023) ซึ่งเป็นขั้นตอนวิธีตัดคำภาษาไทยแบบใช้พจนานุกรม ผู้ใช้งานสามารถเพิ่มคำหรือลบคำออกจากพจนานุกรมได้ ระบุตำแหน่งที่จะแยกคำด้วยยัติภังค์ได้ และสามารถควบคุมขนาดของช่องว่างระหว่างคำหรือระหว่างกลุ่มตัวอักษรในประโยคได้

สารบัญ

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น **2**

1.1 ความต้องการขั้นต่ำของชุดคำสั่ง 2

1.2 วิธีการดาวน์โหลดชุดคำสั่งจากแหล่งต้นทาง 2

1.3 การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร 3

1.4 รายชื่อคำสั่ง 5

2 การตัดคำ และ ช่องว่างระหว่างประโยค **7**

3 กลุ่มตัวอักษร และ การใช้ยัติภังค์ **7**

4 การทำให้เกิดผล **7**

บรรณานุกรม **7**

บทที่

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น

§ 1.1 | ความต้องการขั้นต่ำของชุดคำสั่ง

1. LuaLaTeX รุ่น (เวอร์ชัน) หลังเดือนตุลาคม ปี ค.ศ. 2025 (พ.ศ. 2568)
2. ชุดคำสั่ง `fontspec` และ `polyglossia` ของ LaTeX
3. ชุดแบบอักษรไทย (Thai font)

หมายเหตุ : ณ ขณะนี้ ยังไม่สามารถใช้ชุดคำสั่งนี้กับชุดคำสั่ง `babel` ได้

§ 1.2 | วิธีการดาวน์โหลดชุดคำสั่งจากแหล่งต้นทาง

ในระบบปฏิบัติการ Linux : ให้รันคำสั่งต่อไปนี้ใน bash

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
```

สามารถตรวจสอบว่าชุดคำสั่งพร้อมใช้งานได้ด้วย

```
kpsewhich thai-segmentation.sty
```

ในระบบปฏิบัติการ Windows :

1. ถ้าไม่ได้ตั้งค่า `TEXMFHOME` ไว้ ให้สร้างโฟลเดอร์

   `%USERPROFILE%\texmf\tex\latex\thai-segmentation`

2. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation

3. กดที่ปุ่ม Code สีเขียว แล้วกดดาวน์โหลด ZIP ไฟล์

4. แตกไฟล์ thai-segmentation-main.zip

5. คัดลอกไฟล์ในโฟลเดอร์ที่แตกออกมาไปที่
   %USERPROFILE%\tex\latex\thai-segmentation

ใน ระบบ ปฏิบัติ การ Macs : ยัง ไม่ มี ข้อมูล เนื่องจาก ผู้พัฒนา ชุดคำสั่ง ไม่ มีเงิน เพื่อ ซื้อ Macbook

§ 1.3 | การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร

ตั้งเอกสารให้ใช้ LuaLaTeX และตั้งให้ LaTeX ใช้ภาษาไทยโดยใช้ polyglossia เลือกชุดแบบอักษรที่ต้องการโดยใช fontspec ตัวอย่างเช่น

```
% !TEX program = lualatex
\documentclass{article}

\usepackage{fontspec}
\usepackage{polyglossia}

\newfontfamily{\thaifont}{Sarabun}[Script=Thai]
\newfontfamily{\thaifontsf}{Athiti}[Script=Thai,Scale=MatchUppercase]
\newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX]

\setdefaultlanguage{thai}
\setmainlanguage{thai}
\setotherlanguage{english}
```

ณ ขณะนี้ ยังไม่สามารถใช้ชุดคำสั่งนี้กับชุดคำสั่ง babel ได้

สามารถเรียกใช้ชุดคำสั่งจาก thai-segmentation ได้โดย

```
\usepackage[<options>]{thai-segmentation}
```

สามารถปรับค่าต่าง ๆ ใน <options> ได้ดังนี้

1. วิธีการใช้งานและการตั้งค่าเบื้องต้น

thai-segmentation (true/false) เปิด-ปิดการตัดคำไทย

interword-expansion (true/false) เปิด-ปิดการขยายช่องว่างระหว่างคำในประโยค (เพิ่มเติมในบทที่ 2)

interword-stretch (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดที่ช่องว่างระหว่างคำสามารถขยายได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น 1 ไม่ควรตั้งค่าเกินกว่านี้ เนื่องจากอาจทำให้คำในประโยคห่างกันมากเกินไป

interword-shrink (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดสูงสุดที่ช่องหว่างระหว่างคำสามารถหดได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น 0.5 ไม่ควรตั้งค่าเกินกว่านี้เนื่องจากอาจทำให้คำชิดกันเกินไปหรือซ้อนทับกัน

intercluster-stretch (ทศนิยม) กำหนดระยะห่างเพิ่มเติมระหว่างกลุ่มตัวอักษรไทย (Thai character clusters) จะมีผลก็ต่อเมื่อตั้งเป็นค่าทศนิยมบวก มีค่าปริยายเป็น 0 ควรตั้งค่าให้น้อยกว่า interword-stretch

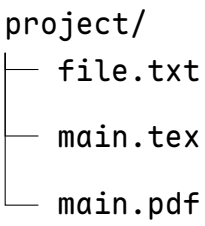
dictionary ระบุที่อยู่ (path) ของไฟล์คำที่จะใส่เพิ่มเข้าพจนานุกรมที่ newmm ใช้ตัดคำ ตัวอย่างเช่น ถ้าโครงสร้างโฟลเดอร์เป็นแบบรูปที่ 1 โดยไฟล์ file.txt มีเนื้อหาดังนี้

file.txt

```
1 ไอน์สไตน์
2 พลังค์
3 แมกซ์เวลล์
```

สามารถเพิ่มคำจากไฟล์ file.txt เข้าพจนานุกรมได้โดยตั้งค่า dictionaries=file.txt (เพิ่มเติมในบทที่ 2)

tcc-min-edge (จำนวนเต็ม) หากคำใดมีตัวอักษรน้อยกว่าค่านี้ จะไม่ใส่จุดตัดคำด้วยยัติ-ภังค์ มีค่าโดยปริยายเป็น 2 (เพิ่มเติมในบทที่ 2)



รูปที่ 1 | *ตัวอย่างโครงสร้างโฟลเดอร์*

show-hyph (true/false) เป็นเครื่องมือสำหรับผู้พัฒนาเพื่อตรวจสอบจุดตัดคำและตำแหน่งการใส่ยัติภังค์ ไม่ควรเปิดใช้ในเอกสารฉบับสมบูรณ์

ตัวอย่างการตั้งค่าและเรียกใช้ชุดคำสั่ง เช่น

```
\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2,
  intercluster-stretch=0,
  dictionary=dict.txt,
  tcc-min-edge=3,
]{thai-segmentation}
```

§ 1.4 | รายชื่อคำสั่ง

\ThaiAddWords{<คำที่หนึ่ง,คำที่สอง,...>} เพิ่มคำเข้าพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างวิธีการใช้เช่น

\ThaiAddwords{ลากรานจ์,แฮมิลตัน,แฮมิลโทเนียน}

\ThaiRemoveWords{<คำที่หนึ่ง,คำที่สอง,...>} ลบคำจากพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างการใช้เช่น

\ThaiRemoveWords{ยั่งยืน,อย่างง่าย}

\ThaiAddHyphenation{<คำ-ที่-หนึ่ง,คำ-ที่-สอง,...>} กำหนด ตำแหน่ง การ ใส่ ยัติภังค์ กรณีที่ระบบตัดคำใส่จุดตัดคำที่ไม่ตรงกับการออกเสียงหรือคำอ่านธรรมชาติ เช่น หากระบบตัดคำว่า "ลากรานจ์" เป็น "ลาก-รานจ์" ซึ่งไม่ตรงกับคำอ่านธรรมชาติ สามารถ

แก้ไขให้ถูกต้องได้ด้วยคำสั่ง

`\ThaiAddHyphenation{ลา-กรานจ์}`

`\ThaiRemoveHyphenation{``คำ-ที่-หนึ่ง,คำ-ที่-สอง`**`}`** ใช้เหมือน `\ThaiAddHyphenation` แต่ใช้เพื่อลบคำสั่งบังคับยัติภังค์ที่กำหนดไว้ก่อนหน้า

`\ThaiAddWordsFromFile{<``ไฟล์พจนานุกรม`**`>}`** นำเข้าไฟล์พจนานุกรมเพิ่มเติม การทำงานเหมือนการกำหนดผ่านการตั้งค่า `dictionary` (ตอนที่ 1.3)

`\ThaiAddSyllables{<``กลุ่มอักษรที่หนึ่ง,กลุ่มอักษรที่สอง,...`**`>}`** เพิ่มกลุ่มอักษรเพื่อใช้ในการใส่ยัติภังค์

`\ThaiRemoveSyllables{<``กลุ่มอักษรที่หนึ่ง,กลุ่มอักษรที่สอง`**`>}`** ลบกลุ่มอักษรออกจากระบบการใส่ยัติภังค์

บทที่ 2

การตัดคำ และ ช่องว่างระหว่างประโยค

บทที่ 3

กลุ่มตัวอักษร และ การใช้ยัติภังค์

บทที่ 4

การทำให้เกิดผล

บรรณานุกรม

Phattiyaphaibun, W., Chaovavanich, K., Polpanumas, C., Suriyawongkul, A., Lowphansirikul, L., Chormai, P., Limkonchotiwat, P., Suntorntip, T., & Udomcharoenchaikit, C. (2023). *PyThaiNLP: Thai Natural Language Processing in Python*.