thai-segmentation
ชุดคำสั่งตัดคำภาษาไทยใน LuaLaTeX

ภูริพัฒน์ ถัมภ์บรรฑุ

31 ตุลาคม พ.ศ. 2569

บทคัดย่อ

ชุดคำสั่งนี้ใช้ตัดคำภาษาไทยใน LuaLaTeX โดยใช้ขั้นตอนวิธี newmm จากโปรแกรม PyThaiNLP (Phattiyaphaibun et al., 2023) ซึ่งเป็นขั้นตอนวิธีตัดคำภาษาไทยแบบใช้พจนานุกรมคำไทย และ หาตำแหน่งแยกคำด้วยยัติภังค์แบบใช้พจนานุกรมพยางค์ ผู้ใช้งานสามารถเพิ่มคำหรือลบคำออกจากพจนานุกรมทั้งสองได้ ระบุตำแหน่งที่จะแยกคำด้วยยัติภังค์ได้ และสามารถควบคุมขนาดของช่องว่างระหว่างคำหรือระหว่างกลุ่มตัวอักษรในประโยคได้

สารบัญ

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น **2**

1.1 ความต้องการขั้นต่ำของชุดคำสั่ง 2

1.2 วิธีการดาวน์โหลดชุดคำสั่ง 2

1.3 การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร 5

1.4 รายชื่อคำสั่ง 8

1.5 คำแนะนำเรื่องการใช้ยัติภังค์ 9

2 การตัดคำและการจัดข้อความให้เต็มบรรทัด **9**

2.1 การตัดคำด้วยยัติภังค์ 10

2.2 การยืดช่องว่างระหว่างคำและพยางค์ 11

2.3 รายละเอียดเชิงลึกของวิธีการจัดบรรทัดของ TeX และข้อจำกัดของชุดคำสั่ง thai-segmentation 11

A การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา 13

บรรณานุกรม 13

บทที่

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น

§ 1.1 | ความต้องการขั้นต่ำของชุดคำสั่ง

1. LuaLaTeX รุ่น (เวอร์ชัน) หลังเดือนตุลาคม ปี ค.ศ. 2025 (พ.ศ. 2568)
   หมายเหตุ : ชุดคำสั่งนี้ ไม่รองรับ pdfTeX **หรือ** XeLaTeX
2. ชุดคำสั่งของ LaTeX ที่ใช้ตั้งเอกสารเป็นภาษาไทย มีให้เลือกสองชุดคำสั่ง ได้แก่ `babel` กับ `polyglossia` ถ้าใช้ `polyglossia` ต้องมีชุดคำสั่ง `fontspec` ด้วย
3. ชุดแบบอักษรไทย (Thai font)
4. แนะนำให้ติดตั้ง `microtype` ด้วย เพื่อให้การจัดวางตัวอักษร (typography) สวยงามกว่าเดิม แต่จะไม่ใช้ก็ได้

สำหรับผู้ใช้ Overleaf : เตรียมแค่ชุดแบบอักษรไทยก็เพียงพอแล้ว

§ 1.2 | วิธีการดาวน์โหลดชุดคำสั่ง

ในระบบปฏิบัติการ Linux : ต้องมีโปรแกรม `git` สามารถดาวน์โหลดโปรแกรมได้ผ่านคู่มือดาวน์โหลดของ `git` (“Git Installation,” 2026)

เมื่อได้ `git` แล้ว ให้รันคำสั่งต่อไปนี้ใน bash (terminal)

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
```

```
rm -rf .git
texhash
```

สามารถตรวจสอบว่าชุดคำสั่งพร้อมใช้งานได้ด้วย

```
kpsewhich thai-segmentation.sty
```

ในระบบปฏิบัติการ Windows :

1. ถ้าไม่ได้ตั้งค่า `TEXMFHOME` ไว้ ให้สร้างโฟลเดอร์ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`
2. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
3. แตกไฟล์ `thai-segmentation-main.zip`
4. คัดลอกไฟล์ทั้งหมดในโฟลเดอร์ที่แตกออกมาไปที่ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`

ถ้าลองเรียกใช้ชุดคำสั่งใน LaTeX แล้วโปรแกรมหาชุดคำสั่งไม่เจอ ให้ปรับแคชของ LaTeX เป็นปัจจุบัน มีอยู่สองวิธี ขึ้นอยู่กับ LaTeX ที่ผู้ใช้งานใช้

MiKTeX เปิด `MiKTeX console` ไปที่ `Tasks` แล้วกด `Refresh file name database` หรือ จะใช้คำสั่ง `initexmf --update -fndb` ใน `powershell` ก็ได้

TeX Live ใช้คำสั่ง `texhash` หรือ `mktexlsr` ใน `powershell`

ใน Overleaf :

1. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`

2. แตกไฟล์ thai-segmentation-main.zip

3. อัพโหลดไฟล์และโฟลเดอร์ต่อไปนี้ลงใน Overleaf (โฟลเดอร์จะลงท้ายด้วย “/”)

    - data/
    - newmm/
    - newmm.lua
    - show_hyph.lua
    - thai_breakpoints.lua
    - thai_linebreak.lua
    - thai_segmentation.lua
    - thai_segmentation.sty

ใน MacOS : เนื่องจากสถานะทางการเงินของผู้พัฒนา จึงไม่มี MacBook และไม่สามารถทดสอบการดาวน์โหลดชุดคำสั่งบน MacOS ได้ ถึงอย่างไรก็ตาม คำสั่งดาวน์โหลด *ควร*จะเหมือนกับคำสั่งใน Linux ทางผู้พัฒนายินดีรับข้อเสนอแนะจากผู้ใช้งาน MacOS เสมอ สามารถติดต่อผู้พัฒนาได้ผ่านทาง https://github.com/AtomThum/thai-segmentation/issues/new

สามารถดาวน์โหลดโปรแกรม git ได้ผ่าน

```
xcode-select --install
```

ตรวจสอบโปรแกรม git ได้ผ่าน

```
git --version
```

เมื่อดาวน์โหลดโปรแกรม git เรียบร้อยแล้ว สามารถดาวน์โหลดชุดคำสั่งนี้ได้ผ่าน

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
texhash
```

§ 1.3 | การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร

ก่อนจะเรียกใช้ชุดคำสั่ง ต้องตั้งให้เอกสารให้เป็นภาษาไทย LuaLaTeX และใช้แบบอักษรไทย มีอยู่สองวิธีดังนี้

ผ่านชุดคำสั่ง `polyglossia` : ให้เรียกใช้ชุดคำสั่ง `fontspec` ก่อนเรียกใช้ `polyglossia` หลังจากนั้นจึงเลือกแบบอักษรที่ต้องการโดยใช้ `fontspec` ตัวอย่างเช่น

```
% !TEX program = lualatex
\documentclass{article}

\usepackage{fontspec}
\usepackage{polyglossia}

\setdefaultlanguage{thai} % ตั้งเอกสารให้เป็นภาษาไทย
\setotherlanguage{english} % ตั้งว่า สามารถมีภาษาอังกฤษแทรกได้

\newfontfamily{\thaifont}{Sarabun}[Script=Thai] % ตั้งแบบอักษรภาษาไทย
↪ ให้เป็น Sarabun
\newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX] % ตั้งแบบอักษร
↪ อังกฤษให้เป็น Sarabun เช่นกัน
% สามารถเปลี่ยนชื่อแบบอักษรที่ต้องการใช้ได้
% ถ้าแบบอักษรไม่ใช่ไฟล์ที่ลงบนเครื่อง สามารถตั้ง Path=... ได้
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง `fontspec` ได้ที่เอกสารสำหรับผู้ใช้งาน `fontspec` และ `polyglossia` ได้ที่คู่มือชุดคำสั่ง (Robertson, 2026) และ (Charette et al., 2026) ตามลำดับ

ผ่านชุดคำสั่ง `babel` : ต้องตั้งค่าให้ `babel` ไม่ใช้ระบบตัดคำไทยของตัวเองโดยใช้คำสั่ง

```
\babelprovide[hyphenrules=nohyphenation]{thai}
```

แล้วค่อยใช้ babel ตั้งเอกสารให้ใช้แบบอักษรไทยโดยคำสั่ง babelfont ตัวอย่างการตั้งค่าเอกสารด้วย babel เช่น

```
% !TEX program = lualatex
\usepackage[thai,english]{babel}
\usepackage[hyphenrules=nohyphenation]{thai} % ปิดการตัดคำของ babel
\babelfont{rm}{Sarabun} % ตั้งแบบอักษรปกติของเอกสาร Sarabun
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง babel ได้ที่คู่มือชุดคำสั่งของ babel (Braams L., 2026)

ถ้ามีชุดคำสั่ง microtype แนะนำให้เรียกใช้ด้วยเพื่อการจัดวางตัวอักษรที่สวยงามกว่าเดิมโดยใช้คำสั่ง

```
\usepackage[protrusion=true,expansion=true,tracking=true]{microtype}
```

หลังจากตั้งค่าเอกสารให้เป็นภาษาไทยเสร็จ สามารถเรียกใช้ชุดคำสั่ง thai-segmentation ได้โดยใช้คำสั่ง

```
\usepackage[<options>]{thai-segmentation}
```

สามารถปรับค่าต่าง ๆ ใน <options> ได้ดังนี้

thai-segmentation (true/false) เปิด-ปิดการตัดคำไทย

interword-expansion (true/false) เปิด-ปิดการขยายช่องว่างระหว่างคำในประโยค (เพิ่มเติมในบทที่ 2)

interword-stretch (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดที่ช่องว่างระหว่างคำสามารถขยายได้ มีหน่วยเป็นพอยต์ (pt) มีค่า

โดยปริยายเป็น 1 ไม่ควรตั้งค่าเกินกว่านี้ เนื่องจากอาจทำให้คำในประโยคห่างกันมากเกินไป

interword-shrink (ทศนิยม) จะมีผลก็ต่อเมื่อ `interword-expansion=true` เท่านั้น กำหนดขนาดสูงสุดที่ช่องหว่างระหว่างคำสามารถหดได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น `0.5` ไม่ควรตั้งค่าเกินกว่านี้เนื่องจากอาจทำให้คำชิดกันเกินไปหรือซ้อนทับกัน

intercluster-stretch (ทศนิยม) กำหนดระยะห่างเพิ่มเติมระหว่างกลุ่มตัวอักษรไทย (Thai character clusters) จะมีผลก็ต่อเมื่อตั้งเป็นค่าทศนิยมบวก มีค่าปริยายเป็น `0` ควรตั้งค่าให้น้อยกว่า `interword-stretch`

dictionary ระบุที่อยู่ (path) ของไฟล์คำที่จะใส่เพิ่มเข้าพจนานุกรมที่ `newmm` ใช้ตัดคำ ตัวอย่างเช่น ถ้าโครงสร้างโฟลเดอร์เป็นแบบรูปที่ 1 โดยไฟล์ `file.txt` มีเนื้อหาดังนี้

`file.txt`

```
1 ไอน์สไตน์
2 พลังค์
3 แมกซ์เวลล์
```

สามารถเพิ่มคำจากไฟล์ `file.txt` เข้าพจนานุกรมได้โดยตั้งค่า `dictionaries=file.txt` (เพิ่มเติมในบทที่ 2)

```
project/
├── file.txt
├── main.tex
└── main.pdf
```

รูปที่ 1 | *ตัวอย่างโครงสร้างโฟลเดอร์*

tcc-min-edge (จำนวนเต็ม) หากคำใดมีตัวอักษรน้อยกว่าค่านี้ จะไม่ใส่จุดตัดคำด้วยยัติภังค์ มีค่าโดยปริยายเป็น 2 (เพิ่มเติมในบทที่ 2)

show-hyph (true/false) เป็นเครื่องมือสำหรับผู้พัฒนาเพื่อตรวจสอบจุดตัดคำและตำแหน่งการใส่ยัติภังค์ ไม่ควรเปิดใช้ในเอกสารฉบับสมบูรณ์

ตัวอย่างการตั้งค่าและเรียกใช้ชุดคำสั่ง เช่น

```
\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2,
  intercluster-stretch=0,
  dictionary=dict.txt,
  tcc-min-edge=3,
]{thai-segmentation}
```

§ 1.4 | รายชื่อคำสั่ง

หมายเหตุ 1 : ในคำสั่งที่รับค่าเป็นรายการคำ เช่น \ThaiAddWords ห้ามเว้นวรรคระหว่างลูกน้ำเด็ดขาด

หมายเหตุ 2 : คำสั่งเหล่านี้ สามารถเรียกใช้งานได้ทุกที่ในเอกสาร โดยจะมีผลกับทุกข้อความที่ตามหลังจุดที่เรียกคำสั่ง แต่จะไม่มีผลกับย่อหน้าก่อนหน้านี้

\ThaiAddWords{<คำที่หนึ่ง,คำที่สอง,...>} เพิ่มคำเข้าพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างวิธีการใช้เช่น \ThaiAddwords{ลากรานจ์,แฮมิลตัน,แฮมิลโทเนียน}

\ThaiRemoveWords{<คำที่หนึ่ง,คำที่สอง,...>} ลบคำจากพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างการใช้เช่น \ThaiRemoveWords{ยั่งยืน,อย่างง่าย}

\ThaiAddHyphenations{<คำ-ที่-หนึ่ง,คำ-ที่-สอง,...>} กำหนดตำแหน่งการใส่ยัติภังค์กรณีที่ระบบตัดคำใส่จุดตัดคำที่ไม่ตรงกับการออกเสียงหรือคำอ่านธรรมชาติ เช่น หากระบบตัดคำว่า "ลากรานจ์" เป็น "ลาก-รานจ์" สามารถแก้ไขให้ถูกต้องได้ด้วยคำสั่ง \ThaiAddHyphenations{ลา-กรานจ์}

\ThaiRemoveHyphenations{คำ-ที่-หนึ่ง,คำ-ที่-สอง**}** ใช้เหมือน \ThaiAddHyphenations แต่ใช้เพื่อลบคำสั่งบังคับยัติภังค์ที่กำหนดไว้ก่อนหน้า

\ThaiAddWordsFromFile{<ไฟล์พจนานุกรม**>}** นำเข้าไฟล์พจนานุกรมเพิ่มเติม การทำงานเหมือนการกำหนดผ่านการตั้งค่า `dictionary` (บทที่ 1.3)

\ThaiAddSyllables{<พยางค์ที่หนึ่ง,พยางค์ที่สอง,...**>}** เพิ่มพยางค์ที่ใช้ในการหาตำแหน่งแยกคำด้วยยัติภังค์

\ThaiRemoveSyllables{<พยางค์ที่หนึ่ง,พยางค์ที่สอง**>}** ลบพยางค์ที่ใช้ในการหาตำแหน่งแยกคำด้วยยัติภังค์

§ 1.5 | คำแนะนำเรื่องการใช้ยัติภังค์

จากหลักการใช้ยัติภังค์ของราชบัณฑิตฯ (สำนักงานราชบัณฑิตยสภา, 2023) *"ยัติภังค์ (-) ใช้เขียนไว้สุดบรรทัดเพื่อต่อพยางค์หรือคำสมาส ซึ่งจำเป็นต้องเขียนแยกบรรทัดกันเนื่องจากเนื้อที่จำกัด"*

บทที่ 2 การตัดคำและการจัดข้อความให้เต็มบรรทัด

เนื่องจากภาษาไทยไม่เขียนเว้นวรรคระหว่างคำในประโยค จึงต้องหาว่าคำ ๆ หนึ่งเริ่มตรงไหนจบตรงไหน นั่นคือ ต้องหาขอบเขตของคำเพื่อจะได้ตัดบรรทัดถูกและสามารถจัดข้อความให้เต็มบรรทัดได้ (text justification) ทาง PyThaiNLP ได้พัฒนาขั้นตอนวิธี `newmm` (Chaovavanich, 2026) เพื่อแก้ปัญหาการหาขอบเขตคำ โดยคร่าว `newmm` จะตัดประโยคให้กลายเป็นกลุ่มตัวอักษรไทย (Thai character clusters) ซึ่งอาจแทนกลุ่มอักษรควบกล้ำ คู่พยัญชนะ-สระ คู่พยัญชนะ-สระ-วรรณยุกต์ ฯลฯ แล้วนำกลุ่มตัวอักษรต่าง ๆ ในประโยคมาเทียบกับพจนานุกรมคำไทย แล้วค่อย**หาจุดตัดคำที่ทำให้คำทั้งหมดในประโยคยาวที่สุดเท่าที่จะเป็นไปได้** เมื่อรู้ขอบเขตระหว่างคำแล้ว จึงสามารถตัดข้อความให้ไม่เกินความยาวบรรทัด แล้วยืดช่องว่างหรือช่องเว้นวรรคเพื่อให้ข้อความเต็มบรรทัด

แต่บ่อยครั้ง ถึงรู้ขอบเขตคำก็อาจไม่สามารถทำให้ข้อความเต็มบรรทัดได้ เนื่องจาก

- คำไทยบางคำนั้นยาวมาก เช่น “โซเดียมไฮโดรเจนกลูทาเมต” หรือ “สำนักงานคณะ-กรรมการป้องกันและปราบปรามการทุจริตและประพฤติมิชอบในวงราชการ” ทำให้หาจุดตัดคำยาก[1]

- ภาษาไทยนั้นเว้นวรรคแค่ระหว่างประโยค จึงไม่ค่อยมีช่องว่างให้ยืดด้วยซ้ำ

นอกจากหาขอบเขตคำ ชุดคำสั่งนี้จึงหาตำแหน่งแยกคำยาว ๆ ด้วยยัติภังค์และเพิ่มช่องว่างระหว่างกลุ่มอักษรกับระหว่างคำด้วย เพื่อการจัดเรียงตัวอักษรที่สวยงามกว่าเดิม

§ 2.1 | การตัดคำด้วยยัติภังค์

หลังจากหาขอบเขตของคำแล้ว ชุดคำสั่งจะไล่ดูคำอีกรอบเพื่อหาตำแหน่งแยกคำด้วยยัติภังค์ ถ้าคำไหนมีจำนวนอักษรเกิน 5 ตัวอักษร จะนำคำไปหากลุ่มอักษรใหม่แล้วใช้ขั้นตอนวิธี `newmm` ตัดคำให้กลายเป็นพยางค์โดยใช้พจนานุกรมพยางค์แทนพจนานุกรมคำไทย เพื่อให้ตำแหน่งแยกคำด้วยยัติภังค์ตรงกับหลักการใช้ยัติภังค์ของราชบัณฑิตฯ (สำนักงานราชบัณฑิตยสภา, 2023) ผู้ใช้งานสามารถเพิ่มพยางค์เข้าพจนานุกรมพยางค์โดยใช้คำสั่ง `\ThaiAddSyllables` รายละเอียดวิธีการใช้คำสั่งนี้อยู่ในบทที่ 1.4

แต่บางครั้ง ตำแหน่งแยกคำนั้นอาจอยู่ติดขอบคำเกิน เช่น `"สมา-ธิ"` หรือ `"ร-ยางค์"` จึกำหนดเงื่อนไขไว้ว่าจะยอมให้ใส่ยัติภังค์ก็ต่อเมื่อตำแหน่งแยกคำด้วยยัติภังค์อยู่ห่างจากขอบคำทั้งสองฝั่งอยู่ `tcc-min-edge` ตัวอักษรเท่านั้น ปกติมีค่าเป็น 2

จากที่กล่าวไว้ในบทที่ 1 บางทีจุดตัดคำจาก `newmm` นั้นอาจไม่ตรงกับการออกเสียงโดยธรรมชาติ สามารถแก้แบบโดยตรงโดยใช้คำสั่ง `\ThaiAddHyphenation` หรือสามารถเพิ่มพยางค์เข้าพจนานุกรมพยางค์โดยใช้คำสั่ง `\ThaiAddSyllables` ได้เช่นกัน

ตัวอย่างคำว่า `"ลากรานจ์"` ซึ่งไม่ได้อยู่ในพจนานุกรมแต่แรก เนื่องจากไม่ใช่คำไทยที่ใช้กันกว้างขว้าง

[1] ทั้งสองคำนี้ อยู่ในพจนานุกรมดั้งเดิมของ `newmm`

- ถ้าใช้พจนานุกรมดั้งเดิมของ newmm คำว่า “ลากรานร์” จะโดนแยกเป็นสองคำ นั่นคือ “ลาก” กับ “รานร์” เนื่องจาก ลาก เป็นคำไทยที่ยาวที่สุดในพจนานุกรมคำของ newmm
- ถ้าเพิ่มคำว่า “ลากรานร์” เข้าพจนานุกรมคำไทย newmm จะเห็นคำเป็นหนึ่งคำ และชุดคำสั่งจะนำคำไปหาจุดตัดด้วยยัติภังค์ต่อเนื่องจากคำมีจำนวนตัวอักษรมากกว่า 5 แต่ newmm ก็ยังคงลงตำแหน่งแยกคำด้วยยัติภังค์เป็น “ลาก-รานร์” อยู่ดี เนื่องจาก “ลาก” อยู่ในพจนานุกรมพยางค์ แต่ “กรานร์” กับ “รานร์” ไม่อยู่
- ถ้าเพิ่ม “ลา” เข้าพจนานุกรมพยางค์ จะไม่ส่งผลเนื่องจากพยางค์ “ลาก” นั้นยาวกว่า “ลา” newmm จึงเลือก “ลาก” ซึ่งเป็นพยางค์ที่ยาวที่สุด
- ถ้าเพิ่ม “กรานร์” เข้าพจนานุกรมพยางค์ จะทำให้ “newmm” ลงตำแหน่งแยกคำด้วยยัติภังค์ถูก เนื่องจากพยางค์ “กรานร์” ยาวกว่าทั้ง “ลา” และ “ลาก” newmm จึงเลือกแยกคำเป็น “ลา-กรานร์”

§ 2.2 | การยืดช่องว่างระหว่างคำและพยางค์

จะสังเกตว่าในเอกสารนี้จะมีช่องว่างเล็ก ๆ ระหว่างขอบเขตของคำ และมีช่องว่างที่เล็กกว่าระหว่างขอบเขตพยางค์ด้วย สามารถเปิดปิดการยืดช่องว่างระหว่างคำได้โดยตั้งค่า `interword-expansion` กำหนดขนาดช่องว่างได้โดย `interword-stretch` และ `interword-expansion` ดังที่กล่าวไว้ในบทที่ 1

§ 2.3 | รายละเอียดเชิงลึกของวิธีการจัดบรรทัดของ TEX และข้อจำกัดของชุดคำสั่ง `thai-segmentation`

ในบทนี้ จะกล่าวถึงข้อจำกัดและรายละเอียดเชิงลึกของ TEX ว่าด้วยระบบแต้มที่ใช้คำนวณตำแหน่งที่เหมาะสมที่สุดที่จะตัดบรรทัด การยืดหรือหดช่องว่าง ฯลฯ แต่จะไม่ครอบคลุมเรื่องขั้นตอนวิธี Knuth-Plass

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับขั้นตอนวิธี Knuth-Plass ได้ที่บทความ “Breaking paragraphs into lines” (Knuth & Plass, 1984) และสามารถหาข้อมูลเกี่ยวกับการทำงาน

เบื้องลึกของ TEX ได้ที่หนังสือ *The* TEX*book* (Knuth, 1984/2021) และหนังสือ TEX *by topic, a* TEX*nician's reference* (Eijkhout, 1991/2007)

TEX แทนหนึ่งหน่วยข้อมูลด้วยโหนด (node) ในรายการโยง (linked list) โหนดที่เกี่ยวข้องกับการตัดคำนั้น นั้นมีอยู่สามชนิด

1. **โหนดจุดยืด (glue node)** ซึ่งคือช่องว่างที่สามารถยืดหรือหดจากความยาวหนึ่งได้ มีค่าความสามารถในการยืดหรือหดตามที่ผู้ใช้งานกำหนด และทำหน้าที่เป็นจุดตัดบรรทัดแบบไม่ใส่ยัติภังค์ TEX จุดยืดสามารถหดได้ถึงแค่ค่าที่ผู้ใช้งานกำหนดเท่านั้น *แต่สามารถยืดได้ไม่จำกัด* อย่างไรก็ตาม TEX จะพยายามไม่ให้โหนดจุดยืดนี้ยืดเกินค่าที่ผู้ใช้งานกำหนดผ่านขั้นตอนวิธี Knuth–Plass ซึ่งจะกล่าวถึงในภายหลัง

2. **โหนดจุดเลือกตัดคำ (discretionary node)** คือจุดที่สามารถตัดคำได้ สามารถกำหนดว่าถ้า TEX เลือกตัดตรงจุดนี้ให้พิมพ์ตัวอักษรอะไรเพิ่มเติม สำหรับภาษาไทย โหนดจุดเลือกตัดคำจะพิมพ์ยัติภังค์ก่อนขึ้นบรรทัดใหม่ แต่ว่า โหนดจุดเลือกตัดคำนี้ไม่สามารถยืดหดได้เหมือนโหนดจุดยืด

3. **โหนดอักขระ (glyph node)** คือตัวอักขระหนึ่งตัว รวมวรรณยุกต์

TEX จะนำข้อความที่ผู้ใช้งานพิมพ์มาแปลงเป็นโหนดเหล่านี้ก่อนที่จะตัดข้อความให้เต็มบรรทัดโดยแปลงตัวอักษรเป็นโหนดอักขระ แปลงเว้นวรรคเป็นโหนดจุดยืด และ แทรกโหนดจุดเลือกตัดคำ โหนดแต่ละโหนดจะมีข้อมูลว่าโหนดไหนตามหลังด้วย เช่น ถ้าเขียนข้อความว่า “ก็ ด” จะถูกแปลงเป็น “โหนดอักขระ ก. ไก่” ตามด้วย “โหนดอักขระ ไม้ไต่คู้” ตามด้วย “โหนดจุดยืด” ตามด้วย “โหนดอักขระ ด. เด็ก” และตามด้วย “โหนดอักขระ สระอี” ซึ่ง TEX จะประมวลผลต่อโดยใช้ขั้นตอนวิธี Knuth–Plass เพื่อจัดบรรทัดให้เต็มโดยอาศัยการยืดและหดของจุดยืด

กล่าวคือ ขั้นตอนวิธี Knuth–Plass จะนำโหนดต่าง ๆ ในบรรทัดมาคำนวณแต้มโทษ (demerit) ซึ่งอาจจะได้แต้มมาจากการยืดโหนดจุดยืดมากเกินไป หรือการตัดคำโดยใช้ยัติภังค์ ซึ่งจะกล่าวถึงในภายหลัง ถ้าแต้มโทษเยอะ ก็ควรเปลี่ยนไปเลือกจุดอื่นตัดบรรทัดแทน ขั้นตอนวิธี Knuth–Plass จะพยายามทำให้แต้มโทษนี้ต่ำที่สุด ซึ่งผู้ใช้งานสามารถปรับน้ำหนักการให้แต้มโทษของแต่ละกรณีได้ มีอยู่สองกรณี ดังนี้

แต้มความบิดเบี้ยว (badness) : คือแต้มที่คำนวณจากการยืดหรือหดโหนดยืด ซึ่งจะคำนวณเป็นอัตราส่วนระหว่างความสามารถในการยืดของโหนดที่ผู้ใช้ตั้งค่าไว้ (max stretch) กับระยะยืดที่ TEX ต้องการเพื่อให้จัดข้อความให้เต็มบรรทัดได้ (actual stretch) แต่จะไม่ให้แต้มความบิดเบี้ยวนั้นเกิน 10000 มีสูตรดังนี้

$$\text{badness} = \left\lfloor 100 \left(\frac{\text{actual stretch}}{\text{max stretch}} \right)^3 \right\rfloor \tag{1}$$

ผู้ใช้งานไม่สามารถตั้งสูตรคำนวณแต้มความบิดเบี้ยวได้ แต่สามารถตั้งว่าให้ TEX ยอมแต้มความบิดเบี้ยวได้เท่าไหร่ผ่าน `\hbadness`

แต้มค่าปรับ (penalty) : คือแต้มที่คำนวณจากการ

แต่เนื่องจาก TEX นั้นออกแบบมาให้พิมพ์ภาษาอังกฤษ[2] TEX เลยไม่รู้ว่าจะใส่จุดตัดคำไทยในประโยคอย่างไร

บทที่ A

การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา

ผู้พัฒนาชุดคำสั่งได้พัฒนาส่วนต่อประสานระหว่าง LuaLATEX และขั้นตอนวิธี `newmm` เองได้เขียนคู่มือการใช้งานทั้งภาษาไทยและภาษาอังกฤษเอง แต่ใช้ Claude Opus 5.5 เพื่อช่วยแปลขั้นตอนวิธี `newmm` จากโปรแกรม `PyThaiNLP` ให้เป็นภาษา Lua และได้ใช้เพื่อแก้ไวยากรณ์ภาษาอังกฤษ

บรรณานุกรม

Braams L., J. (2026, October 29). *Babel user guide: Localization and internationalization* (J. Bezos, Cont.). Version 26.15.

[2] TEX เริ่มรองรับภาษาอื่น ๆ ในปี 1989 โดยชุดคำสั่ง `babel` ซึ่งมาหลัง TEX เอง 12 ปี และเริ่มรองรับภาษาไทยในปี 2013

Chaovavanich, K. (2026, October 7). *PyThaiNLP: newmm algorithm implementation* [The algorithm based on notebook by Chaovavanich, Korakot. Others in the PyThaiNLP team also contributed to the algorithm]. Retrieved November 3, 2026, from https://github.com/PyThaiNLP/pythainlp/blob/main/pythainlp/tokenize/newmm.py

Charette, F., Reutenauer, A., Fogiel, U., Roucariès, & Spitzmüller, J. (2026, September 11). *Polyglossia: Modern multilingual typesetting with* XeLaTeX *and* LuaLaTeX. Version 2.13. Retrieved November 2, 2026, from https://texdoc.org/serve/polyglossia/0

Eijkhout, V. (2007, October 2). TeX *by topic, a* TeX*nician's reference* [Book was originally printed in 1991 by Addison-Wesley UK. The pdf version was made available in 2001, and appeared on CTAN in 2007]. Retrieved November 4, 2026, from https://ctan.org/pkg/texbytopic?lang=en (Original work published 1991)

Git Installation. (2026) (2.56.0). Retrieved November 3, 2026, from https://git-scm.com/install/linux

Knuth, D. E. (2021, February). *The* TeX*book* (35th Jubilee Edition). Addison-Wesley. (Original work published 1984)

Knuth, D. E., & Plass, M. F. (1984). Breaking paragraphs into lines. *Software – Practice and Experience*, *11*, 1119–1184. https://gwern.net/doc/design/typography/tex/1981-knuth.pdf

Phattiyaphaibun, W., Chaovavanich, K., Polpanumas, C., Suriyawongkul, A., Lowphansirikul, L., Chormai, P., Limkonchotiwat, P., Suntorntip, T., & Udomcharoenchaikit, C. (2023). *PyThaiNLP: Thai Natural Language Processing in Python*.

Robertson, W. (2026, August 11). *The fontspec package* (P. Gesand, J. Wright et al., Collab.). Version 2.9h. Retrieved November 2, 2026, from https://texdoc.org/serve/fontspec/0

สำนักงานราชบัณฑิตยสภา. (2023). *หลักเกณฑ์การใช้เครื่องหมายวรรคตอน – ยัติภังค์*. สำนักงานราชบัณฑิตยสภา. Retrieved November 4, 2026, from https://www.orst.go.th/iwfm_table.asp?a=36&i=0040002104011001%2F63erk0249069