ชุดคำสั่งตัดคำภาษาไทยใน LuaLaTeX

ภูริพัฒน์ ถัมภ์บรรฑุ

31 ตุลาคม พ.ศ. 2569

บทคัดย่อ

ชุดคำสั่งนี้ใช้ตัดคำภาษาไทยใน LuaLaTeX โดยใช้ขั้นตอนวิธี `newmm` จากโปรแกรม PyThaiNLP (Phattiyaphaibun et al., 2023) ซึ่งเป็นขั้นตอนวิธีตัดคำภาษาไทยแบบใช้พจนานุกรม ผู้ใช้งานสามารถเพิ่มคำหรือลบคำออกจากพจนานุกรมได้ ระบุตำแหน่งที่จะแยกคำด้วยยัติภังค์ได้ และสามารถควบคุมขนาดของช่องว่างระหว่างคำหรือระหว่างกลุ่มตัวอักษรในประโยคได้

สารบัญ

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น **2**

1.1 ความต้องการขั้นต่ำของชุดคำสั่ง 2

1.2 วิธีการดาวน์โหลดชุดคำสั่ง 2

1.3 การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร 4

1.4 รายชื่อคำสั่ง 7

2 การตัดคำ และ ช่องว่างระหว่างประโยค **8**

3 กลุ่มตัวอักษร และ การใช้ยัติภังค์ **9**

4 การทำให้เกิดผล **9**

บรรณานุกรม **9**

บทที่

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น

§ 1.1 | ความต้องการขั้นต่ำของชุดคำสั่ง

1. LuaLaTeX รุ่น (เวอร์ชัน) หลังเดือนตุลาคม ปี ค.ศ. 2025 (พ.ศ. 2568)
   หมายเหตุ : ชุดคำสั่งนี้ ไม่รองรับ pdfTeX **หรือ** XeLaTeX

2. ชุดคำสั่งของ LaTeX ที่ใช้ตั้งเอกสารเป็นภาษาไทย มีให้เลือกสองชุดคำสั่ง ได้แก่ `babel` กับ `polyglossia` ถ้าใช้ `polyglossia` ต้องมีชุดคำสั่ง `fontspec` ด้วย

3. ชุดแบบอักษรไทย (Thai font)

4. แนะนำให้ติดตั้ง `microtype` ด้วย เพื่อให้การจัดวางตัวอักษร (typography) สวยงามกว่าเดิม แต่จะไม่ใช้ก็ได้

สำหรับผู้ใช้ Overleaf : เตรียมแค่ชุดแบบอักษรไทยก็เพียงพอแล้ว

§ 1.2 | วิธีการดาวน์โหลดชุดคำสั่ง

ในระบบปฏิบัติการ Linux : ให้รันคำสั่งต่อไปนี้ใน bash

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
```

สามารถตรวจสอบว่าชุดคำสั่งพร้อมใช้งานได้ด้วย

```
kpsewhich thai-segmentation.sty
```

ในระบบปฏิบัติการ Windows :

1. ถ้าไม่ได้ตั้งค่า `TEXMFHOME` ไว้ ให้สร้างโฟลเดอร์ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`
2. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
3. แตกไฟล์ `thai-segmentation-main.zip`
4. คัดลอกไฟล์ทั้งหมดในโฟลเดอร์ที่แตกออกมาไปที่ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`

ใน Overleaf :

1. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
2. แตกไฟล์ `thai-segmentation-main.zip`
3. อัพโหลดไฟล์และโฟลเดอร์ต่อไปนี้ลงใน Overleaf
    - `data/`
    - `newmm/`
    - `newmm.lua`
    - `show_hyph.lua`
    - `thai_breakpoints.lua`
    - `thai_linebreak.lua`
    - `thai_segmentation.lua`
    - `thai_segmentation.sty`

ในระบบปฏิบัติการ Macs : ยังไม่มีข้อมูลเนื่องจากผู้พัฒนาไม่มีเงินเพื่อซื้อ Macbook

§ 1.3 | การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร

ก่อนจะเรียกใช้ชุดคำสั่ง ต้องตั้งให้เอกสารให้เป็นภาษาไทย LuaLaTeX และใช้แบบอักษรไทย มีอยู่สองวิธีดังนี้

ผ่านชุดคำสั่ง `polyglossia` : ให้เรียกใช้ชุดคำสั่ง `fontspec` ก่อนเรียกใช้ `polyglossia` หลังจากนั้นจึงเลือกแบบอักษรที่ต้องการโดยใช้ `fontspec` ตัวอย่างเช่น

```
% !TEX program = lualatex
\documentclass{article}

\usepackage{fontspec}
\usepackage{polyglossia}

\newfontfamily{\thaifont}{Sarabun}[Script=Thai]
\newfontfamily{\thaifontsf}{Athiti}[Script=Thai,Scale=MatchUppercase]
\newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX]

\setdefaultlanguage{thai}
\setotherlanguage{english}
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง `fontspec` ได้ที่เอกสารสำหรับผู้ใช้งาน `fontspec` (Robertson, 2026) และกับ `polyglossia` ได้ที่เอกสารสำหรับผู้ใช้งานชุดคำสั่ง `polyglossia` (Charette et al., 2026)

ผ่านชุดคำสั่ง `babel` : ต้องตั้งค่าให้ `babel` ไม่ใช้ระบบตัดคำไทยของตัวเองโดยใช้คำสั่ง

```
\babelprovide[hyphenrules=nohyphenation]{thai}
```

แล้วค่อยใช้ `babel` ตั้งเอกสารให้ใช้แบบอักษรไทยโดยคำสั่ง `babelfont` ตัวอย่างการตั้งค่าเอกสารด้วย `babel` เช่น

```
% !TEX program = lualatex
\usepackage[thai,english]{babel}
\usepackage[hyphenrules=nohyphenation]{thai}
\babelfont{rm}{Sarabun}
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง babel ได้ที่เอกสารสำหรับผู้ใช้งานชุดคำสั่ง babel (Braams L., 2026)

หลังจากตั้งค่าเอกสารให้เป็นภาษาไทยเสร็จ ถึงสามารถเรียกใช้ชุดคำสั่ง thai-segmentation ได้โดยใช้คำสั่ง

```
\usepackage[<options>]{thai-segmentation}
```

สามารถปรับค่าต่าง ๆ ใน <options> ได้ดังนี้

thai-segmentation (true/false) เปิด-ปิดการตัดคำไทย

interword-expansion (true/false) เปิด-ปิดการขยายช่องว่างระหว่างคำในประโยค (เพิ่มเติมในบทที่ 2)

interword-stretch (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดที่ช่องว่างระหว่างคำสามารถขยายได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น 1 ไม่ควรตั้งค่าเกินกว่านี้ เนื่องจากอาจทำให้คำในประโยคห่างกันมากเกินไป

interword-shrink (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดสูงสุดที่ช่องหว่างระหว่างคำสามารถหดได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น 0.5 ไม่ควรตั้งค่าเกินกว่านี้เนื่องจากอาจทำให้คำชิดกันเกินไปหรือซ้อนทับกัน

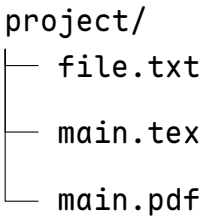
intercluster-stretch (ทศนิยม) กำหนดระยะห่างเพิ่มเติมระหว่างกลุ่มตัวอักษรไทย (Thai character clusters) จะมีผลก็ต่อเมื่อตั้งเป็นค่าทศนิยมบวก มีค่าปริยายเป็น 0 ควรตั้งค่าให้น้อยกว่า interword-stretch

dictionary ระบุที่อยู่ (path) ของไฟล์คำที่จะใส่เพิ่มเข้าพจนานุกรมที่ newmm ใช้ตัดคำ ตัวอย่างเช่น ถ้าโครงสร้างโฟลเดอร์เป็นแบบรูปที่ 1 โดยไฟล์ file.txt มีเนื้อหาดังนี้

file.txt

```
ไอน์สไตน์
พลังค์
แมกซ์เวลล์
```

สามารถเพิ่มคำจากไฟล์ file.txt เข้าพจนานุกรมได้โดยตั้งค่า dictionaries=file.txt (เพิ่มเติมในบทที่ 2)



รูปที่ 1 | *ตัวอย่างโครงสร้างโฟลเดอร์*

tcc-min-edge (จำนวนเต็ม) หากคำใดมีตัวอักษรน้อยกว่าค่านี้ จะไม่ใส่จุดตัดคำด้วยยัติภังค์ มีค่าโดยปริยายเป็น 2 (เพิ่มเติมในบทที่ 2)

show-hyph (true/false) เป็นเครื่องมือสำหรับผู้พัฒนาเพื่อตรวจสอบจุดตัดคำและตำแหน่งการใส่ยัติภังค์ ไม่ควรเปิดใช้ในเอกสารฉบับสมบูรณ์

ตัวอย่างการตั้งค่าและเรียกใช้ชุดคำสั่ง เช่น

```
\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2,
  intercluster-stretch=0,
  dictionary=dict.txt,
  tcc-min-edge=3,
]{thai-segmentation}
```

§ 1.4 | รายชื่อคำสั่ง

\ThaiAddWords{<คำที่หนึ่ง**,**คำที่สอง**, ...>}** เพิ่มคำเข้าพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างวิธีการใช้เช่น

\ThaiAddwords{ลากรานจ์,แฮมิลตัน,แฮมิลโทเนียน}

\ThaiRemoveWords{<คำที่หนึ่ง**,**คำที่สอง**, ...>}** ลบคำจากพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างการใช้เช่น

\ThaiRemoveWords{ยั่งยืน,อย่างง่าย}

\ThaiAddHyphenation{<คำ-ที่-หนึ่ง**,**คำ-ที่-สอง**, ...>}** กำหนด ตำแหน่ง การ ใส่ ยัติภังค์ กรณีที่ระบบตัดคำใส่จุดตัดคำที่ไม่ตรงกับการออกเสียงหรือคำอ่านธรรมชาติ เช่น หากระบบตัดคำว่า "ลากรานจ์" เป็น "ลาก-รานจ์" ซึ่งไม่ตรงกับคำอ่านธรรมชาติ สามารถแก้ไขให้ถูกต้องได้ด้วยคำสั่ง

\ThaiAddHyphenation{ลา-กรานจ์}

\ThaiRemoveHyphenation{คำ-ที่-หนึ่ง**,**คำ-ที่-สอง**}** ใช้เหมือน \ThaiAddHyphenation แต่ใช้เพื่อลบคำสั่งบังคับยัติภังค์ที่กำหนดไว้ก่อนหน้า

\ThaiAddWordsFromFile{<ไฟล์พจนานุกรม**>}** นำเข้าไฟล์พจนานุกรมเพิ่มเติม การทำงานเหมือนการกำหนดผ่านการตั้งค่า dictionary (ตอนที่ 1.3)

\ThaiAddSyllables{<กลุ่มอักษรที่หนึ่ง**,**กลุ่มอักษรที่สอง**, ...>}** เพิ่มกลุ่มอักษรเพื่อใช้ในการใส่ยัติภังค์

\ThaiRemoveSyllables{<กลุ่มอักษรที่หนึ่ง**,**กลุ่มอักษรที่สอง**>}** ลบกลุ่มอักษรออกจากระบบการใส่ยัติภังค์

บทที่

2 การตัดคำ และ ช่องว่างระหว่างประโยค

บทที่ 3

กลุ่มตัวอักษร และ การใช้ยัติภังค์

บทที่ 4

การทำให้เกิดผล

บรรณานุกรม

Braams L., J. (2026, October 29). *Babel user guide: Localization and internationalization* (J. Bezos, Cont.). Version 26.15.

Charette, F., Reutenauer, A., Fogiel, U., Roucariès, & Spitzmüller, J. (2026, September 11). *Polyglossia: Modern multilingual typesetting with* XeLaTeX *and* LuaLaTeX. Version 2.13. https://texdoc.org/serve/polyglossia/0

Phattiyaphaibun, W., Chaovavanich, K., Polpanumas, C., Suriyawongkul, A., Lowphansirikul, L., Chormai, P., Limkonchotiwat, P., Suntorntip, T., & Udomcharoenchaikit, C. (2023). *PyThaiNLP: Thai Natural Language Processing in Python*.

Robertson, W. (2026, August 11). *The fontspec package* (P. Gesand, J. Wright et al., Collab.). Version 2.9h. https://texdoc.org/serve/fontspec/0