ชุดคำสั่งตัดคำภาษาไทยใน LuaLaTeX

ภูริพัฒน์ ถัมภ์บรรฑุ

31 ตุลาคม พ.ศ. 2569

บทคัดย่อ

ชุดคำสั่งนี้ใช้ตัดคำภาษาไทยใน LuaLaTeX โดยใช้ขั้นตอนวิธี `newmm` จากโปรแกรม PyThaiNLP (Phattiyaphaibun et al., 2023) ซึ่งเป็นขั้นตอนวิธีตัดคำภาษาไทยแบบใช้พจนานุกรม ผู้ใช้งานสามารถเพิ่มคำหรือลบคำออกจากพจนานุกรมได้ ระบุตำแหน่งที่จะแยกคำด้วยยัติภังค์ได้ และสามารถควบคุมขนาดของช่องว่างระหว่างคำหรือระหว่างกลุ่มตัวอักษรในประโยคได้

สารบัญ

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น **2**

1.1 ความต้องการขั้นต่ำของชุดคำสั่ง 2

1.2 วิธีการดาวน์โหลดชุดคำสั่ง 2

1.3 การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร 4

1.4 รายชื่อคำสั่ง 7

2 การตัดคำ และ การจัดข้อความให้เต็มบรรทัด **8**

2.1 การตัดคำด้วยยัติภังค์ 9

2.2 การเพิ่มช่องว่างระหว่างคำ 9

3 กลุ่มตัวอักษร และ การใช้ยัติภังค์ **9**

4 การทำให้เกิดผล **9**

A การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา **9**

บทที่ 1

วิธีการใช้งานและการตั้งค่าเบื้องต้น

§ 1.1 | ความต้องการขั้นต่ำของชุดคำสั่ง

1. LuaLaTeX รุ่น (เวอร์ชัน) หลังเดือนตุลาคม ปี ค.ศ. 2025 (พ.ศ. 2568)
   หมายเหตุ : ชุดคำสั่งนี้ ไม่รองรับ pdfTeX **หรือ** XeLaTeX

2. ชุดคำสั่งของ LaTeX ที่ใช้ตั้งเอกสารเป็นภาษาไทย มีให้เลือกสองชุดคำสั่ง ได้แก่ `babel` กับ `polyglossia` ถ้าใช้ `polyglossia` ต้องมีชุดคำสั่ง `fontspec` ด้วย

3. ชุดแบบอักษรไทย (Thai font)

4. แนะนำให้ติดตั้ง `microtype` ด้วย เพื่อให้การจัดวางตัวอักษร (typography) สวยงามกว่าเดิม แต่จะไม่ใช้ก็ได้

สำหรับผู้ใช้ Overleaf : เตรียมแค่ชุดแบบอักษรไทยก็เพียงพอแล้ว

§ 1.2 | วิธีการดาวน์โหลดชุดคำสั่ง

ในระบบปฏิบัติการ Linux : ให้รันคำสั่งต่อไปนี้ใน bash

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
```

สามารถตรวจสอบว่าชุดคำสั่งพร้อมใช้งานได้ด้วย

1. วิธีการใช้งานและการตั้งค่าเบื้องต้น

```
kpsewhich thai-segmentation.sty
```

ในระบบปฏิบัติการ Windows :

1. ถ้าไม่ได้ตั้งค่า `TEXMFHOME` ไว้ ให้สร้างโฟลเดอร์ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`
2. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
3. แตกไฟล์ `thai-segmentation-main.zip`
4. คัดลอกไฟล์ทั้งหมดในโฟลเดอร์ที่แตกออกมาไปที่ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`

ใน Overleaf :

1. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
2. แตกไฟล์ `thai-segmentation-main.zip`
3. อัพโหลดไฟล์และโฟลเดอร์ต่อไปนี้ลงใน Overleaf
    - `data/`
    - `newmm/`
    - `newmm.lua`
    - `show_hyph.lua`
    - `thai_breakpoints.lua`
    - `thai_linebreak.lua`

- `thai_segmentation.lua`
- `thai_segmentation.sty`

ในระบบปฏิบัติการ Macs : ยังไม่มีข้อมูลเนื่องจากผู้พัฒนาไม่มีเงินเพื่อซื้อ Macbook

§ 1.3 | การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร

ก่อนจะเรียกใช้ชุดคำสั่ง ต้องตั้งให้เอกสารให้เป็นภาษาไทย LuaLaTeX และใช้แบบอักษรไทย มีอยู่สองวิธีดังนี้

ผ่านชุดคำสั่ง `polyglossia` : ให้เรียกใช้ชุดคำสั่ง `fontspec` ก่อนเรียกใช้ `polyglossia` หลังจากนั้นจึงเลือกแบบอักษรที่ต้องการโดยใช้ `fontspec` ตัวอย่างเช่น

```
% !TEX program = lualatex
\documentclass{article}

\usepackage{fontspec}
\usepackage{polyglossia}

\setdefaultlanguage{thai} % ตั้งเอกสารให้เป็นภาษาไทย
\setotherlanguage{english} % ตั้งว่า สามารถมีภาษาอังกฤษแทรกได้

\newfontfamily{\thaifont}{Sarabun}[Script=Thai] % ตั้งแบบอักษรภาษาไทย
↪ ให้เป็น Sarabun
\newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX] % ตั้งแบบอักษร
↪ อังกฤษให้เป็น Sarabun เช่นกัน
% สามารถเปลี่ยนชื่อแบบอักษรที่ต้องการใช้ได้
% ถ้าแบบอักษรไม่ใช่ไฟล์ที่ลงบนเครื่อง สามารถตั้ง Path=... ได้
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง `fontspec` ได้ที่เอกสารสำหรับผู้ใช้งาน `fontspec` และ `polyglossia` ได้ที่คู่มือชุดคำสั่ง (Robertson, 2026) และ (Charette et al., 2026) ตามลำดับ

ผ่านชุดคำสั่ง `babel` : ต้องตั้งค่าให้ `babel` ไม่ใช้ระบบตัดคำไทยของตัวเองโดยใช้คำสั่ง

1. วิธีการใช้งานและการตั้งค่าเบื้องต้น

```
\babelprovide[hyphenrules=nohyphenation]{thai}
```

แล้วค่อยใช้ babel ตั้งเอกสารให้ใช้แบบอักษรไทยโดยคำสั่ง babelfont ตัวอย่างการตั้งค่าเอกสารด้วย babel เช่น

```
% !TEX program = lualatex
\usepackage[thai,english]{babel}
\usepackage[hyphenrules=nohyphenation]{thai} % ปิดการตัดคำของ babel
\babelfont{rm}{Sarabun} % ตั้งแบบอักษรปกติของเอกสาร Sarabun
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง babel ได้ที่คู่มือชุดคำสั่ง babel (Braams L., 2026)

ถ้ามีชุดคำสั่ง microtype แนะนำให้เรียกใช้ด้วยเพื่อการจัดวางตัวอักษรที่สวยงามกว่าเดิม โดยใช้คำสั่ง

```
\usepackage[protrusion=true,expansion=true,tracking=true]{microtype}
```

หลังจากตั้งค่าเอกสารให้เป็นภาษาไทยเสร็จ ถึงเรียกใช้ชุดคำสั่ง thai-segmentation ได้โดยใช้คำสั่ง

```
\usepackage[<options>]{thai-segmentation}
```

สามารถปรับค่าต่าง ๆ ใน <options> ได้ดังนี้

thai-segmentation (true/false) เปิด-ปิดการตัดคำไทย

interword-expansion (true/false) เปิด-ปิดการขยายช่องว่างระหว่างคำในประโยค (เพิ่มเติมในบทที่ 2)

interword-stretch (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดที่ช่องว่างระหว่างคำสามารถขยายได้ มีหน่วยเป็นพอยต์ (pt) มีค่า

โดยปริยายเป็น 1 ไม่ควรตั้งค่าเกินกว่านี้ เนื่องจากอาจทำให้คำในประโยคห่างกันมากเกินไป

interword-shrink (ทศนิยม) จะมีผลก็ต่อเมื่อ `interword-expansion=true` เท่านั้น กำหนดขนาดสูงสุดที่ช่องหว่างระหว่างคำสามารถหดได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น `0.5` ไม่ควรตั้งค่าเกินกว่านี้เนื่องจากอาจทำให้คำชิดกันเกินไปหรือซ้อนทับกัน

intercluster-stretch (ทศนิยม) กำหนดระยะห่างเพิ่มเติมระหว่างกลุ่มตัวอักษรไทย (Thai character clusters) จะมีผลก็ต่อเมื่อตั้งเป็นค่าทศนิยมบวก มีค่าปริยายเป็น `0` ควรตั้งค่าให้น้อยกว่า `interword-stretch`

dictionary ระบุที่อยู่ (path) ของไฟล์คำที่จะใส่เพิ่มเข้าพจนานุกรมที่ `newmm` ใช้ตัดคำ ตัวอย่างเช่น ถ้าโครงสร้างโฟลเดอร์เป็นแบบรูปที่ 1 โดยไฟล์ `file.txt` มีเนื้อหาดังนี้

file.txt

```
ไอน์สไตน์
พลังค์
แมกซ์เวลล์
```

สามารถเพิ่มคำจากไฟล์ `file.txt` เข้าพจนานุกรมได้โดยตั้งค่า `dictionaries=file.txt` (เพิ่มเติมในบทที่ 2)

```
project/
├── file.txt
├── main.tex
└── main.pdf
```

รูปที่ 1 | *ตัวอย่างโครงสร้างโฟลเดอร์*

tcc-min-edge (จำนวนเต็ม) หากคำใดมีตัวอักษรน้อยกว่าค่านี้ จะไม่ใส่จุดตัดคำด้วยยัติ-ภังค์ มีค่าโดยปริยายเป็น 2 (เพิ่มเติมในบทที่ 2)

show-hyph (true/false) เป็นเครื่องมือสำหรับผู้พัฒนาเพื่อตรวจสอบจุดตัดคำและตำแหน่งการใส่ยัติภังค์ ไม่ควรเปิดใช้ในเอกสารฉบับสมบูรณ์

ตัวอย่างการตั้งค่าและเรียกใช้ชุดคำสั่ง เช่น

```
\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2,
  intercluster-stretch=0,
  dictionary=dict.txt,
  tcc-min-edge=3,
]{thai-segmentation}
```

§ 1.4 | รายชื่อคำสั่ง

หมายเหตุ : ในคำสั่งที่รับค่าเป็นรายการคำ เช่น \ThaiAddWords ห้ามเว้นวรรคระหว่างลูกน้ำเด็ดขาด

\ThaiAddWords{<คำที่หนึ่ง,คำที่สอง,...>} เพิ่มคำเข้าพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างวิธีการใช้เช่น
\ThaiAddwords{ลากรานจ์,แฮมิลตัน,แฮมิลโทเนียน}

\ThaiRemoveWords{<คำที่หนึ่ง,คำที่สอง,...>} ลบคำจากพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างการใช้เช่น
\ThaiRemoveWords{ยั่งยืน,อย่างง่าย}

\ThaiAddHyphenations{<คำ-ที่-หนึ่ง,คำ-ที่-สอง,...>} กำหนดตำแหน่งการใส่ยัติภังค์ กรณีที่ระบบตัดคำใส่จุดตัดคำที่ไม่ตรงกับการออกเสียงหรือคำอ่านธรรมชาติ เช่น หากระบบตัดคำว่า "ลากรานจ์" เป็น "ลาก-รานจ์" ซึ่งไม่ตรงกับคำอ่านธรรมชาติ สามารถแก้ไขให้ถูกต้องได้ด้วยคำสั่ง
\ThaiAddHyphenations{ลา-กรานจ์}

\ThaiRemoveHyphenations{คำ-ที่-หนึ่ง,คำ-ที่-สอง} ใช้เหมือน \ThaiAddHyphenations แต่ใช้เพื่อลบคำสั่งบังคับยัติภังค์ที่กำหนดไว้ก่อนหน้า

\ThaiAddWordsFromFile{<ไฟล์พจนานุกรม>} นำเข้าไฟล์พจนานุกรมเพิ่มเติม การทำงานเหมือนการกำหนดผ่านการตั้งค่า `dictionary` (ตอนที่ 1.3)

\ThaiAddSyllables{<กลุ่มอักษรที่หนึ่ง,กลุ่มอักษรที่สอง,...>} เพิ่มกลุ่มอักษรเพื่อใช้ในการใส่ยัติภังค์

\ThaiRemoveSyllables{<กลุ่มอักษรที่หนึ่ง,กลุ่มอักษรที่สอง>} ลบกลุ่มอักษรออกจากระบบการใส่ยัติภังค์

บทที่ 2 การตัดคำ และ การจัดข้อความให้เต็มบรรทัด

เนื่องจากภาษาไทยใช้ระบบการเขียนที่ไม่เว้นวรรคระหว่างคำ จึงต้องมีกระบวนการหาว่าขอบเขตของคำ ๆ หนึ่งอยู่ตรงไหน เพื่อที่จะได้ตัดบรรทัดถูก ซึ่งทาง PyThaiNLP ได้พัฒนาขั้นตอนวิธี `newmm` แก้ปัญหานี้

กล่าวโดยคร่าว ขั้นตอนวิธี `newmm` นั้น จะตัดประโยคหนึ่งให้กลายเป็นกลุ่มตัวอักษรไทย (Thai character clusters) ด้วยขั้นตอนวิธี `onecut` หนึ่งกลุ่มตัวอักษรอาจแทนกลุ่มตัวอักษรควบกล้ำ กลุ่มตัวอักษรกับสระ หรือ กลุ่มตัวอักษรที่ติดกับวรรณยุกต์ หลังจากนั้น `newmm` จะนำกลุ่มตัวอักษรเหล่านั้นไปเทียบกับพจนานุกรมคำไทย โดยจะพยายามให้หนึ่งคำนั้นยาวที่สุดเท่าที่จะเป็นไปได้ เพื่อหาขอบเขตของคำ

แต่บ่อยครั้ง ถึงรู้ว่าจุดตัดคำไทยอยู่ตรงไหนก็อาจไม่เพียงพอสำหรับการจัดข้อความให้เป็นบรรทัดได้ (text justification) เนื่องจากคำบางคำนั้นยาวจนไม่สามารถหาที่จุดตัดประโยคให้ลงตัวได้ เช่น คำว่า "ไฮโดรเจนเปอร์ออกไซด์" หรือ "กฎมณเฑียรบาลว่าด้วยการสืบราชสันตติวงศ์" แล้วยิ่งภาษาไทยนั้นเว้นวรรคแค่ระหว่างประโยค ซึ่งน้อยมากเทียบกับภาษาอังกฤษที่ใช้เว้นวรรค์ระหว่างทุกคำ ช่องว่างที่มีจะให้ยืดเพื่อจัดข้อความให้เต็มบรรทัด

ได้จึงน้อยลงตาม จึงแทบไม่สามารถจัดคำไทยให้เต็มบรรทัดได้ ชุดคำสั่งนี้จึงทำเพิ่มสองอย่าง ได้แก่ การหาตำแหน่งตัดคำยาว ๆ ด้วยยัติภังค์ และ การเพิ่มช่องว่างระหว่างกลุ่มอักษรไทยกับระหว่างคำ

§ 2.1 | การตัดคำด้วยยัติภังค์

ชุดคำสั่งนี้จะหาตำแหน่งตัดคำด้วยยัติภังค์ก็ต่อเมื่อคำนั้นมีจำนวนอักษรเกิน 5 ตัวอักษรเท่านั้น และจะวางจุดตัดยัติภังค์ให้อยู่ตรงกลางคำ เพื่อให้ไม่มีการตัดคำแบบ "เ-ครื่องยนต์" หรือ "ระยะห่า-ง" ขึ้น สามารถกำหนดจำนวนตัวอักษรก่อนที่จากซ้ายหรือขวาของคำก่อนที่จะใส่ยัติภังค์ได้โดยตั้งค่า `tcc-min-edge` ซึ่งปกติแล้วจะมีค่าเท่ากับ 3

จากที่กล่าวไว้ในบทที่ 1 บางทีจุดตัดคำที่หาจากกลุ่มตัวอักษรไทยนั้น อาจไม่ตรงกับจุดใส่ยัติภังค์โดยธรรมชาติ สามารถแก้ได้โดย `\ThaiAddHyphenation`

§ 2.2 | การเพิ่มช่องว่างระหว่างคำ

บทที่ 3 กลุ่มตัวอักษร และ การใช้ยัติภังค์

บทที่ 4 การทำให้เกิดผล

บทที่ A การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา

ผู้พัฒนาชุดคำสั่งได้พัฒนาส่วนต่อประสานระหว่าง LuaLaTeX และขั้นตอนวิธี `newmm` เอง แต่ใช้ปัญญาประดิษฐ์เพื่อช่วยแปลขั้นตอนวิธี `newmm` จากโปรแกรม `PyThaiNLP` ให้เป็นภาษา

Lua โมเดลปัญญาประดิษฐ์ที่ใช้คือ Claude Opus 5.5

บรรณานุกรม

Braams L., J. (2026, October 29). *Babel user guide: Localization and internationalization* (J. Bezos, Cont.). Version 26.15.

Charette, F., Reutenauer, A., Fogiel, U., Roucariès, & Spitzmüller, J. (2026, September 11). *Polyglossia: Modern multilingual typesetting with* XeLaTeX *and* LuaLaTeX. Version 2.13. https://texdoc.org/serve/polyglossia/0

Phattiyaphaibun, W., Chaovavanich, K., Polpanumas, C., Suriyawongkul, A., Lowphansirikul, L., Chormai, P., Limkonchotiwat, P., Suntorntip, T., & Udomcharoenchaikit, C. (2023). *PyThaiNLP: Thai Natural Language Processing in Python*.

Robertson, W. (2026, August 11). *The fontspec package* (P. Gesand, J. Wright et al., Collab.). Version 2.9h. https://texdoc.org/serve/fontspec/0