thai-segmentation
ชุดคำสั่งตัดคำภาษาไทยใน LuaLaTeX

นายภูริพัฒน์ ถัมภ์บรรฑุ

พิมพ์ฉบับแรกวันที่ : 31 ตุลาคม พ.ศ. 2569
ฉบับปัจจุบัน : 5 พฤศจิกายน พ.ศ. 2569

บทคัดย่อ

ชุดคำสั่งนี้ (package) ใช้ตัดคำภาษาไทยใน LuaLaTeX โดยใช้ขั้นตอนวิธี `newmm` จากโปรแกรม PyThaiNLP (Phattiyaphaibun et al., 2023) ซึ่งเป็นขั้นตอนวิธีตัดคำภาษาไทยแบบใช้พจนานุกรมคำไทย และ หาตำแหน่งแยกคำด้วยยัติภังค์แบบใช้พจนานุกรมพยางค์ ผู้ใช้งานสามารถเพิ่มคำหรือลบคำออกจากพจนานุกรมทั้งสองได้ ระบุตำแหน่งที่จะแยกคำด้วยยัติภังค์ได้ และสามารถควบคุมขนาดของช่องว่างระหว่างคำหรือระหว่างกลุ่มตัวอักษรในประโยคได้

สารบัญ

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น **2**

1.1 ความต้องการขั้นต่ำของชุดคำสั่ง 2
1.2 วิธีการดาวน์โหลดชุดคำสั่ง 3
1.3 ตัวอย่างการใช้งานสั้น ๆ กับชุดคำสั่ง `polyglossia` 5
1.4 การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร 6
1.5 รายชื่อคำสั่ง 9
1.6 คำแนะนำเรื่องการใช้ยัติภังค์ 10

2 การตัดคำและการจัดข้อความให้เต็มบรรทัด 10
2.1 การแยกคำด้วยยัติภังค์ 11
2.2 การยืดช่องว่างระหว่างคำและพยางค์ 12
2.3 รายละเอียดเชิงลึกของวิธีการจัดบรรทัดของ TEX และข้อจำกัดของชุดคำสั่ง `thai-segmentation` 12

3 การเชื่อม LuaLATEX กับ `newmm` 17
3.1 ระบบคอลแบ็ก 17
3.2 ระบบแคช 17

A การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา 17

บรรณานุกรม 18

บทที่

1 วิธีการใช้งานและการตั้งค่าเบื้องต้น

§ 1.1 | ความต้องการขั้นต่ำของชุดคำสั่ง

1. LuaLATEX รุ่นหลังเดือนตุลาคม ปี ค.ศ. 2025 (พ.ศ. 2568)
   หมายเหตุ : ชุดคำสั่งนี้ ไม่รองรับ pdfTEX **หรือ** XHLATEX

2. ชุดคำสั่ง (package) ของ LATEX ที่ใช้ตั้งเอกสารเป็นภาษาไทย มีให้เลือกสองชุดคำสั่ง ได้แก่ `babel` กับ `polyglossia`
   หมายเหตุ : ถ้าใช้ `polyglossia` ต้องมีชุดคำสั่ง `fontspec` ด้วย

3. ชุดแบบอักษรไทย (Thai font)

4. แนะนำให้ติดตั้ง `microtype` ด้วย เพื่อให้การจัดวางตัวอักษร (typography) สวยงามกว่าเดิม แต่จะไม่ใช้ก็ได้

สำหรับผู้ใช้ Overleaf : เตรียมแค่ชุดแบบอักษรไทยก็เพียงพอแล้ว

§ 1.2 | วิธีการดาวน์โหลดชุดคำสั่ง

ในระบบปฏิบัติการ Linux : ต้องมีโปรแกรม `git` สามารถดาวน์โหลดโปรแกรมได้ผ่านคู่มือดาวน์โหลดของ `git` (“Git Installation,” 2026)

เมื่อได้ `git` แล้ว ให้รันคำสั่งต่อไปนี้ใน bash (terminal)

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
texhash
```

สามารถตรวจสอบว่าชุดคำสั่งพร้อมใช้งานได้ด้วย

```
kpsewhich thai-segmentation.sty
```

ในระบบปฏิบัติการ Windows :

1. ถ้าไม่ได้ตั้งค่า `TEXMFHOME` ไว้ ให้สร้างโฟลเดอร์ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`
2. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ `thai-segmentation-main.zip`
3. แตกไฟล์ `thai-segmentation-main.zip`
4. คัดลอกไฟล์ทั้งหมดในโฟลเดอร์ที่แตกออกมาไปที่ `%USERPROFILE%\texmf\tex\latex\thai-segmentation`

ถ้าลองเรียกใช้ชุดคำสั่งใน LaTeX แล้วโปรแกรมหาชุดคำสั่งไม่เจอ ให้ปรับแคชของ LaTeX เป็นปัจจุบัน มีอยู่สองวิธี ขึ้นอยู่กับ LaTeX ที่ผู้ใช้งานใช้

1. วิธีการใช้งานและการตั้งค่าเบื้องต้น

MiKTeX เปิด MiKTeX console ไปที่ Tasks แล้วกด Refresh file name database หรือ จะใช้คำสั่ง initexmf --update -fndb ใน powershell ก็ได้

TeX Live ใช้คำสั่ง texhash หรือ mktexlsr ใน powershell

ใน Overleaf :

1. ไปที่ยูอาร์แอล https://github.com/AtomThum/thai-segmentation/archive/refs/heads/main.zip เพื่อดาวน์โหลดไฟล์ thai-segmentation-main.zip
2. แตกไฟล์ thai-segmentation-main.zip
3. อัพโหลดไฟล์และโฟลเดอร์ต่อไปนี้ลงใน Overleaf (โฟลเดอร์จะลงท้ายด้วย “/”)
    - data/
    - newmm/
    - newmm.lua
    - show_hyph.lua
    - thai_breakpoints.lua
    - thai_linebreak.lua
    - thai_segmentation.lua
    - thai_segmentation.sty

ใน MacOS : เนื่องจากผู้พัฒนาไม่มีเครื่องที่ใช้ MacOS จึงไม่สามารถทดสอบการดาวน์โหลดใน MacOS ได้ อย่างไรก็ตาม คำสั่งดาวน์โหลด*ควร*จะเหมือนกับคำสั่งใน Linux ทางผู้พัฒนายินดีรับข้อเสนอแนะจากผู้ใช้งาน MacOS เสมอ สามารถติดต่อผู้พัฒนาได้ผ่านทาง https://github.com/AtomThum/thai-segmentation/issues/new

สามารถดาวน์โหลดโปรแกรม git ได้ผ่าน

---

1. วิธีการใช้งานและการตั้งค่าเบื้องต้น

```
xcode-select --install
```

ตรวจสอบโปรแกรม git ได้ผ่าน

```
git --version
```

เมื่อดาวน์โหลดโปรแกรม git แล้ว สามารถดาวน์โหลดชุดคำสั่งนี้ได้ผ่าน

```
mkdir -p $(kpsewhich -var-value TEXMFHOME)/tex/latex
cd $(kpsewhich -var-value TEXMFHOME)/tex/latex
git clone https://github.com/AtomThum/thai-segmentation
rm -rf .git
texhash
```

§ 1.3 | ตัวอย่างการใช้งานสั้น ๆ กับชุดคำสั่ง polyglossia

```
% !TEX program = lualatex
\documentclass{article}

\usepackage{fontspec}
\usepackage{polyglossia}

% กำหนดแบบอักษรภาษาไทยและอังกฤษ เปลี่ยนเป็นชื่อแบบอักษรในเครื่องหรือ Overleaf ได้
\newfontfamily{\thaifont}{Sarabun}[Script=Thai]
\newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX]

\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2
]{thai-segmentation}
\hyphenpenalty=500

\begin{document}
นี่คือข้อความทดสอบการตัดคำและจัดบรรทัดภาษาไทยใน LuaLaTeX โดยใช้ newmm
เนื่องจากภาษาไทยไม่เว้นวรรคระหว่างคำในประโยค
```

```
21 จึงต้องหาขอบเขตของคำเพื่อใส่ยัติภังค์และยืดช่องว่างระหว่างคำ
22 เพื่อที่จะจัดข้อความให้เต็มบรรทัดได้อย่างสวยงาม
23 \end{document}
```

§ 1.4 | การเรียกใช้งานชุดคำสั่งและการตั้งค่าเอกสาร

ก่อนจะเรียกใช้ชุดคำสั่ง ให้ตรวจสอบว่ากำลังใช้งาน LuaLaTeX อยู่ ไม่ใช่ pdfTeX หรือ XeLaTeX หลังจากนั้น ตั้งเอกสารให้เป็นภาษาไทยและใช้แบบอักษรไทย มีอยู่สองวิธีดังนี้

ผ่านชุดคำสั่ง `polyglossia` : ให้เรียกใช้ชุดคำสั่ง `fontspec` ก่อนเรียกใช้ `polyglossia` หลังจากนั้นจึงเลือกแบบอักษรที่ต้องการโดยใช้ `fontspec` ตัวอย่างเช่น

```
1  % !TEX program = lualatex
2  \documentclass{article}
3
4  \usepackage{fontspec}
5  \usepackage{polyglossia}
6
7  \setdefaultlanguage{thai} % ตั้งเอกสารให้เป็นภาษาไทย
8  \setotherlanguage{english} % บอก polyglossia ว่า สามารถมีภาษาอังกฤษแทรก
   ↪  ในเอกสารได้
9
10 \newfontfamily{\thaifont}{Sarabun}[Script=Thai] % ตั้งแบบอักษรภาษาไทย
   ↪  ให้เป็น Sarabun
11 \newfontfamily{\englishfont}{Sarabun}[Ligatures=TeX] % ตั้งแบบอักษร
   ↪  อังกฤษให้เป็น Sarabun เช่นกัน
12 % สามารถเปลี่ยนชื่อแบบอักษรที่ต้องการใช้ได้
13 % ถ้าแบบอักษรไม่ใช่ไฟล์ที่ลงบนเครื่อง สามารถตั้ง Path=... ได้
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง `fontspec` ได้ที่เอกสารสำหรับผู้ใช้งาน `fontspec` และ `polyglossia` ได้ที่คู่มือชุดคำสั่ง (Robertson, 2026) และ (Charette et al., 2026) ตามลำดับ

ผ่านชุดคำสั่ง `babel` : ต้องตั้งค่าให้ `babel` ไม่ใช้ระบบตัดคำไทยของตัวเองโดยใช้คำสั่ง

```
\babelprovide[hyphenrules=nohyphenation]{thai}
```

แล้วค่อยใช้ babel ตั้งเอกสารให้ใช้แบบอักษรไทยโดยคำสั่ง babelfont ตัวอย่างการตั้งค่าเอกสารด้วย babel เช่น

```
% !TEX program = lualatex
\usepackage[thai,english]{babel}
\usepackage[hyphenrules=nohyphenation]{thai} % ปิดการตัดคำของ babel
\babelfont{rm}{Sarabun} % ตั้งแบบอักษรปกติของเอกสาร Sarabun
```

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับชุดคำสั่ง babel ได้ที่คู่มือชุดคำสั่งของ babel (Braams L., 2026)

ถ้ามีชุดคำสั่ง microtype แนะนำให้เรียกใช้ด้วยเพื่อการจัดวางตัวอักษรที่สวยงามกว่าเดิมโดยใช้คำสั่ง

```
\usepackage[protrusion=true,expansion=true,tracking=true]{microtype}
```

หลังจากตั้งค่าเอกสารให้เป็นภาษาไทยเสร็จ สามารถเรียกใช้ชุดคำสั่ง thai-segmentation ได้โดยใช้คำสั่ง

```
\usepackage[<options>]{thai-segmentation}
```

สามารถปรับค่าต่าง ๆ ใน <options> ได้ดังนี้

thai-segmentation (true/false) เปิด-ปิดการตัดคำไทย

interword-expansion (true/false) เปิด-ปิดการขยายช่องว่างระหว่างคำในประโยค (เพิ่มเติมในบทที่ 2)

interword-stretch (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดที่ช่องว่างระหว่างคำสามารถขยายได้ มีหน่วยเป็นพอยต์ (pt) มี

ค่าโดยปริยายเป็น 1 ไม่ควรตั้งค่าเกินกว่านี้ เนื่องจากอาจทำให้คำในประโยคห่างกันมากเกินไป

interword-shrink (ทศนิยม) จะมีผลก็ต่อเมื่อ interword-expansion=true เท่านั้น กำหนดขนาดสูงสุดที่ช่องว่างระหว่างคำสามารถหดได้ มีหน่วยเป็นพอยต์ (pt) มีค่าโดยปริยายเป็น 0.5 ไม่ควรตั้งค่าเกินกว่านี้เนื่องจากอาจทำให้คำชิดกันเกินไปหรือซ้อนทับกัน

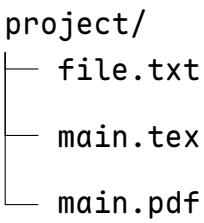
intercluster-stretch (ทศนิยม) กำหนดระยะห่างเพิ่มเติมระหว่างกลุ่มตัวอักษรไทย (Thai character clusters) จะมีผลก็ต่อเมื่อตั้งเป็นค่าทศนิยมบวก มีค่าปริยายเป็น 0 ควรตั้งค่าให้น้อยกว่า interword-stretch

dictionary ระบุที่อยู่ (path) ของไฟล์คำที่จะใส่เพิ่มเข้าพจนานุกรมที่ newmm ใช้ตัดคำ ตัวอย่างเช่น ถ้าโครงสร้างโฟลเดอร์เป็นแบบรูปที่ 1 โดยไฟล์ file.txt มีเนื้อหาดังนี้

file.txt

```
ไอน์สไตน์
พลังค์
แมกซ์เวลล์
```

สามารถเพิ่มคำจากไฟล์ file.txt เข้าพจนานุกรมได้โดยตั้งค่า dictionaries=file.txt (เพิ่มเติมในบทที่ 2)



รูปที่ 1 | *ตัวอย่างโครงสร้างโฟลเดอร์*

tcc-min-edge (จำนวนเต็ม) ยอมให้ใส่ยัติภังค์ก็ต่อเมื่อตำแหน่งแยกคำด้วยยัติภังค์อยู่ห่างจากขอบคำทั้งสองฝั่งอยู่ tcc-min-edge เท่านั้น มีค่าโดยปริยายเป็น 2 (เพิ่มเติมในบทที่ 2)

show-hyph (true/false) เป็นเครื่องมือสำหรับผู้พัฒนาเพื่อตรวจสอบจุดตัดคำและตำแหน่งการใส่ยัติภังค์ ไม่ควรเปิดใช้ในเอกสารฉบับสมบูรณ์

ตัวอย่างการตั้งค่าและเรียกใช้ชุดคำสั่ง เช่น

```
\usepackage[
  interword-expansion=true,
  interword-stretch=0.5,
  interword-shrink=0.2,
  intercluster-stretch=0,
  dictionary=dict.txt,
  tcc-min-edge=3,
]{thai-segmentation}
```

§ 1.5 | รายชื่อคำสั่ง

หมายเหตุ 1 : ในคำสั่งที่รับค่าเป็นรายการคำ เช่น \ThaiAddWords ห้ามเว้นวรรคระหว่างลูกน้ำเด็ดขาด

หมายเหตุ 2 : คำสั่งเหล่านี้ สามารถเรียกใช้งานได้ทุกที่ในเอกสาร โดยจะมีผลกับทุกข้อความที่ตามหลังจุดที่เรียกคำสั่ง แต่จะไม่มีผลกับย่อหน้าก่อนหน้านี้

\ThaiAddWords{<คำที่หนึ่ง,คำที่สอง,...>} เพิ่มคำเข้าพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างวิธีการใช้เช่น \ThaiAddWords{ลากรานจ์,แฮมิลตัน,แฮมิลโทเนียน}

\ThaiRemoveWords{<คำที่หนึ่ง,คำที่สอง,...>} ลบคำจากพจนานุกรมของ newmm รับค่าเหมือน dictionaries ในการตั้งค่าชุดคำสั่ง ตัวอย่างการใช้เช่น \ThaiRemoveWords{ยั่งยืน,อย่างง่าย}

\ThaiAddHyphenations{<คำ-ที่-หนึ่ง,คำ-ที่-สอง,...>} กำหนดตำแหน่งการใส่ยัติภังค์กรณีที่ระบบตัดคำใส่จุดตัดคำที่ไม่ตรงกับการออกเสียงหรือคำอ่านธรรมชาติ เช่น หากระบบตัดคำว่า "ลากรานจ์" เป็น "ลาก-รานจ์" สามารถแก้ไขให้ถูกต้องได้ด้วยคำสั่ง \ThaiAddHyphenations{ลา-กรานจ์}

\ThaiRemoveHyphenations{คำ-ที่-หนึ่ง,คำ-ที่-สอง**}** ใช้เหมือน \ThaiAddHyphenations แต่ใช้เพื่อลบคำสั่งบังคับยัติภังค์ที่กำหนดไว้ก่อนหน้า

\ThaiAddWordsFromFile{<ไฟล์พจนานุกรม**>}** นำเข้าไฟล์พจนานุกรมเพิ่มเติม การทำงานเหมือนการกำหนดผ่านการตั้งค่า `dictionary` (บทที่ 1.4)

\ThaiAddSyllables{<พยางค์ที่หนึ่ง,พยางค์ที่สอง,...**>}** เพิ่มพยางค์ที่ใช้ในการหาตำแหน่งแยกคำด้วยยัติภังค์

\ThaiRemoveSyllables{<พยางค์ที่หนึ่ง,พยางค์ที่สอง**>}** ลบพยางค์ที่ใช้ในการหาตำแหน่งแยกคำด้วยยัติภังค์

§ 1.6 | คำแนะนำเรื่องการใช้ยัติภังค์

จากหลักการใช้ยัติภังค์ของราชบัณฑิตฯ (สำนักงานราชบัณฑิตยสภา, 2023) *"ยัติภังค์ (-) ใช้เขียนไว้สุดบรรทัดเพื่อต่อพยางค์หรือคำสมาส ซึ่งจำเป็นต้องเขียนแยกบรรทัดกันเนื่องจากเนื้อที่จำกัด"*

บทที่ 2 การตัดคำและการจัดข้อความให้เต็มบรรทัด

เนื่องจากภาษาไทยไม่เขียนเว้นวรรคระหว่างคำในประโยค จึงต้องหาว่าคำคำหนึ่งเริ่มตรงไหนจบตรงไหน นั่นคือ ต้องหาขอบเขตของคำเพื่อจะได้ตัดบรรทัดถูกและสามารถจัดข้อความให้เต็มบรรทัดได้ (text justification) ทาง PyThaiNLP ได้พัฒนาขั้นตอนวิธี `newmm` (Chaovavanich, 2026) เพื่อแก้ปัญหาการหาขอบเขตคำ โดยคร่าว `newmm` จะตัดประโยคให้กลายเป็นกลุ่มตัวอักษรไทย (Thai character clusters) ซึ่งอาจแทนกลุ่มอักษรควบกล้ำ คู่พยัญชนะ-สระ คู่พยัญชนะ-สระ-วรรณยุกต์ ฯลฯ แล้วนำกลุ่มตัวอักษรต่าง ๆ ในประโยคมาเทียบกับพจนานุกรมคำไทย แล้วค่อย**หาจุดตัดคำที่ทำให้คำทั้งหมดในประโยคยาวที่สุดเท่าที่จะเป็นไปได้** เมื่อรู้ขอบเขตระหว่างคำแล้ว จึงสามารถตัดข้อความให้ไม่เกิน

ความยาวบรรทัด แล้วยืดช่องว่างหรือช่องเว้นวรรคเพื่อให้ข้อความเต็มบรรทัด แต่บ่อยครั้งถึงรู้ขอบเขตคำก็อาจไม่สามารถทำให้ข้อความเต็มบรรทัดได้ เนื่องจาก

- คำไทยบางคำนั้นยาวมาก เช่น “โซเดียมไฮโดรเจนกลูทาเมต” หรือ “สำนักงาน-คณะกรรมการป้องกันและปราบปรามการทุจริตและประพฤติมิชอบในวงราชการ” ทำให้หาจุดตัดคำยาก[1]

- ภาษาไทยนั้นเว้นวรรคแค่ระหว่างประโยค จึงไม่ค่อยมีช่องว่างให้ยืดด้วยซ้ำ

นอกจากหาขอบเขตคำ ชุดคำสั่งนี้จึงหาตำแหน่งแยกคำยาว ๆ ด้วยยัติภังค์และเพิ่มช่องว่างระหว่างกลุ่มอักษรกับระหว่างคำด้วย เพื่อการจัดเรียงตัวอักษรที่สวยงามกว่าเดิม

§ 2.1 | การแยกคำด้วยยัติภังค์

หลังจากหาขอบเขตของคำแล้ว ชุดคำสั่งจะไล่ดูคำอีกรอบเพื่อหาตำแหน่งแยกคำด้วยยัติภังค์ ถ้าคำไหนมีจำนวนอักษรเกิน 5 ตัวอักษร จะนำคำไปหากลุ่มอักษรใหม่แล้วใช้ขั้นตอนวิธี `newmm` ตัดคำให้กลายเป็นพยางค์โดยใช้พจนานุกรมพยางค์แทนพจนานุกรมคำไทย เพื่อให้ตำแหน่งแยกคำด้วยยัติภังค์ตรงกับหลักการใช้ยัติภังค์ของราชบัณฑิตฯ (สำนักงานราชบัณฑิตยสภา, 2023)

แต่บางครั้ง ตำแหน่งแยกคำนั้นอาจอยู่ติดขอบคำเกิน เช่น `"สมา-ธิ"` หรือ `"ร-ยางค์"` จึงกำหนดเงื่อนไขไว้ว่าจะยอมให้ใส่ยัติภังค์ก็ต่อเมื่อตำแหน่งแยกคำด้วยยัติภังค์อยู่ห่างจากขอบคำทั้งสองฝั่งอยู่ `tcc-min-edge` ตัวอักษรเท่านั้น ปกติมีค่าเป็น 2

จากที่กล่าวไว้ในบทที่ 1 บางทีจุดตัดคำจาก `newmm` นั้นอาจไม่ตรงกับการออกเสียงโดยธรรมชาติ สามารถแก้แบบโดยตรงโดยใช้คำสั่ง `\ThaiAddHyphenations` หรือสามารถเพิ่มพยางค์เข้าพจนานุกรมพยางค์โดยใช้คำสั่ง `\ThaiAddSyllables` ได้เช่นกัน

ตัวอย่างคำว่า `"ลากรานจ์"` ซึ่งไม่ได้อยู่ในพจนานุกรมแต่แรก เนื่องจากไม่ใช่คำไทยที่ใช้กันกว้างขว้าง

[1] ทั้งสองคำนี้ อยู่ในพจนานุกรมดั้งเดิมของ `newmm`

- ถ้าใช้พจนานุกรมดั้งเดิมของ newmm คำว่า “ลากรานร์” จะโดนแยกเป็นสองคำ นั่นคือ “ลาก” กับ “รานร์” เนื่องจาก ลาก เป็นคำไทยที่ยาวที่สุดในพจนานุกรมคำของ newmm
- ถ้าเพิ่มคำว่า “ลากรานร์” เข้าพจนานุกรมคำไทย newmm จะเห็นคำเป็นหนึ่งคำ และชุดคำสั่งจะนำคำไปหาจุดตัดด้วยยัติภังค์ต่อเนื่องจากคำมีจำนวนตัวอักษรมากกว่า 5 แต่ newmm ก็ยังคงลงตำแหน่งแยกคำด้วยยัติภังค์เป็น “ลาก-รานร์” อยู่ดี เนื่องจาก “ลาก” อยู่ในพจนานุกรมพยางค์ แต่ “กรานร์” กับ “รานร์” ไม่อยู่
- ถ้าเพิ่ม “ลา” เข้าพจนานุกรมพยางค์ จะไม่ส่งผลเนื่องจากพยางค์ “ลาก” นั้นยาวกว่า “ลา” newmm จึงเลือก “ลาก” ซึ่งเป็นพยางค์ที่ยาวที่สุด
- ถ้าเพิ่ม “กรานร์” เข้าพจนานุกรมพยางค์ จะทำให้ “newmm” ลงตำแหน่งแยกคำด้วยยัติภังค์ถูก เนื่องจากพยางค์ “กรานร์” ยาวกว่าทั้ง “ลา” และ “ลาก” newmm จึงเลือกแยกคำเป็น “ลา-กรานร์”

§ 2.2 | การยืดช่องว่างระหว่างคำและพยางค์

จะสังเกตว่าในเอกสารนี้จะมีช่องว่างเล็ก ๆ ระหว่างขอบเขตของคำ และมีช่องว่างที่เล็กกว่าระหว่างขอบเขตพยางค์ด้วย สามารถเปิดปิดการยืดช่องว่างระหว่างคำได้โดยตั้งค่า `interword-expansion` กำหนดขนาดช่องว่างได้โดย `interword-stretch` และ `interword-shrink` ดังที่กล่าวไว้ในบทที่ 1

§ 2.3 | รายละเอียดเชิงลึกของวิธีการจัดบรรทัดของ TEX และข้อจำกัดของชุดคำสั่ง thai-segmentation

ในบทนี้ จะกล่าวถึงข้อจำกัดและรายละเอียดเชิงลึกของ TEX ว่าด้วยระบบแต้มที่ใช้คำนวณตำแหน่งที่เหมาะสมที่สุดที่จะตัดบรรทัด การยืดหรือหดช่องว่าง ฯลฯ แต่จะไม่ครอบคลุมเรื่องขั้นตอนวิธี Knuth-Plass

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับขั้นตอนวิธี Knuth-Plass ได้ที่บทความ “Breaking paragraphs into lines” (Knuth & Plass, 1984) และสามารถหาข้อมูลเกี่ยวกับการทำงาน

เบื้องลึกของ TEX ได้ที่หนังสือ *The* TEX*book* (Knuth, 1984/2021) และหนังสือ TEX *by topic, a* TEX*nician's reference* (Eijkhout, 1991/2007)

TEX แทนหนึ่งหน่วยข้อมูลด้วยโหนด (node) ในรายการโยง (linked list) โหนดที่เกี่ยวข้องกับการตัดคำนั้น นั้นมีอยู่สามชนิด

1. **โหนดระยะช่องไฟ (glue node)** แทน ช่องว่างที่สามารถยืดหรือหดจากระยะปกติที่ตั้งค่าไว้ได้ มีความสามารถในการยืดหรือหดตามที่ผู้ใช้งานกำหนด และทำหน้าที่เป็นจุดตัดบรรทัดแบบไม่ใส่ยัติภังค์ TEX โหนดระยะช่องไฟสามารถหดได้ถึงแค่ค่าที่ผู้ใช้งานกำหนดเท่านั้น *แต่สามารถยืดได้ไม่จำกัด* อย่างไรก็ตาม TEX จะพยายามไม่ให้โหนดระยะช่องไฟนี้ยืดเกินค่าที่ผู้ใช้งานกำหนดผ่านขั้นตอนวิธี Knuth–Plass ซึ่งจะกล่าวถึงในภายหลัง
   สามารถกำหนดระยะต่าง ๆ ของโหนดช่องไฟที่เกิดจากเว้นวรรคได้โดยใช้ตัวแปร `spaceskip`[2]

```
\spaceskip=A plus B minus C
```

   โดย `A` คือระยะปกติ `B` คือความสามารถในการยืด และ `C` คือความสามารถในการหด มีหน่วยเป็นความยาวใด ๆ ก็ได้ หรือ สามารถกำหนดเป็นเท่าตัวของระยะเริ่มต้นที่ TEX กำหนดไว้ก็ได้

```
\spaceskip=x\fontdimen2 plus y\fontdimen3 minus z\fontdimen4
```

2. **โหนดจุดเลือกตัดคำ (discretionary node)** คือจุดที่สามารถตัดคำได้ สามารถกำหนดว่าถ้า TEX เลือกตัดตรงจุดนี้ให้พิมพ์ตัวอักษรอะไรเพิ่มเติม สำหรับภาษาไทย จะมีโหนดจุดเลือกตัดคำสองแบบ นั่นคือ แบบที่พิมพ์ยัติภังค์ก่อนขึ้นบรรทัดใหม่ ใช้ตัดระหว่างขอบเขตคำ และ แบบที่ไม่พิมพ์ยัติภังค์ ใช้ตัด ณ ขอบเขตคำ โหนดจุดเลือกตัดคำนี้ไม่สามารถยืดหดได้เหมือนโหนดระยะช่องไฟ

[2]ถ้าใช้ชุดคำสั่ง `fontspec` สามารถตั้งค่า `WordSpace={A,B,C}` ตอนเลือกแบบอักษรได้ เช่น `\newfontfamily{\thaifont}{Niramit}[Script=Thai,WordSpace={1.75,2.25,0.75}]`

3. โหนดอักขระ (glyph node) คือตัวอักขระหนึ่งตัว รวมวรรณยุกต์

TEX จะนำข้อความที่ผู้ใช้งานพิมพ์มาแปลงเป็นโหนดเหล่านี้ก่อนที่จะตัดข้อความให้เต็มบรรทัดโดยแปลงตัวอักษรเป็นโหนดอักขระ แปลงเว้นวรรคเป็นโหนดระยะช่องไฟ และแทรกโหนดจุดเลือกตัดคำ โหนดแต่ละโหนดจะมีข้อมูลว่าโหนดไหนตามหลังด้วย เช่น ถ้าเขียนข้อความว่า “ก็ ด” จะถูกแปลงเป็น “โหนดอักขระ ก. ไก่” ตามด้วย “โหนดอักขระ ไม้ไต่คู้” ตามด้วย “โหนดระยะช่องไฟ” ตามด้วย “โหนดอักขระ ด. เด็ก” และตามด้วย “โหนดอักขระ สระอี” ซึ่ง TEX จะประมวลผลต่อโดยใช้ขั้นตอนวิธี Knuth–Plass เพื่อจัดบรรทัดให้เต็มโดยอาศัยการยืดและหดของจุดยืด

กล่าวคือ ขั้นตอนวิธี Knuth–Plass จะนำโหนดต่าง ๆ ในบรรทัดมาคำนวณแต้มเสีย (demerit) ซึ่งอาจจะได้แต้มมาจากการยืดโหนดระยะช่องไฟมากเกินไป หรือการตัดคำโดยใช้ยัติภังค์ ซึ่งจะกล่าวถึงในภายหลัง ถ้าแต้มเสียเยอะ ก็ควรเปลี่ยนไปเลือกจุดอื่นตัดบรรทัดแทน ขั้นตอนวิธี Knuth–Plass จะพยายามทำให้แต้มเสียนี้ต่ำที่สุด ซึ่งผู้ใช้งานสามารถปรับน้ำหนักการให้แต้มเสียของแต่ละกรณีได้ มีอยู่สองกรณี ดังนี้

badness : คือแต้มที่คำนวณจากการยืดหรือหดของโหนดระยะช่องไฟ ซึ่งขึ้นกับอัตราส่วนระหว่างความสามารถในการยืดโหนดระยะช่องไฟที่ผู้ใช้ตั้งค่าไว้ (max stretch) กับระยะยืดที่ TEX ต้องการเพื่อให้จัดข้อความให้เต็มบรรทัดได้ (actual stretch) แต่จะไม่ให้แต้มความบิดเบี้ยวนั้นเกิน 10000 มีสูตรดังนี้

$$\text{badness} = \left\lfloor 100 \left(\frac{\text{actual stretch}}{\text{max stretch}} \right)^3 \right\rfloor \tag{1}$$

ผู้ใช้งานไม่สามารถตั้งสูตรคำนวณแต้มความบิดเบี้ยวได้ แต่สามารถตั้งความสามารถในการยืด (max stretch) ผ่าน `spaceskip` ได้

สังเกตว่า `badness` นั้นขึ้นกับอัตราส่วนกำลังสาม ดังนั้น ถ้าโหนดระยะช่องไฟยืดหรือหดไม่เกินความสามารถในการยืดหด แต้ม `badness` จะน้อยมาก ๆ เนื่องจากอัตราส่วนนั้นน้อยกว่าหนึ่ง พอนำไปกำลังสามจะได้เลขที่น้อยกว่าเดิม แต่ `badness` จะมีผลถ้ายืดโหนดระยะช่องไฟเกินความสามารถ

hyphenpenalty/exhyphenpenalty : โหนดจุดเลือกตัดคำทั้งหมดจะมีแต้ม penalty อยู่ ซึ่งจะนำมาคำนวณเป็น penalty ของย่อหน้าก็ต่อเมื่อ TEX เลือกตัดบรรทัดที่โหนดจุดเลือกตัดคำเท่านั้น ถ้าแต้ม penalty สูง TEX ก็จะพยายามไม่เลือกตัดบรรทัดที่โหนดนั้น แต่ถ้า penalty ต่ำ TEX ก็จะยอมรับการตัดคำ ณ จุดนั้นมากขึ้น โดยแต้ม penalty ของโหนดเลือกตัดคำมีค่าได้ตั้งแต่ -10000 ถึง 10000 โดยมีค่าปกติของโหนดจุดเลือกตัดคำที่เกิดขึ้นจากยัติภังค์เป็น 50 สามารถปรับค่านี้ได้โดยใช้คำสั่ง \hyphenpenalty=... ถ้าตั้งค่านี้เป็น 10000 TEX จะไม่ยอมตัดบรรทัดที่โหนดจุดเลือกตัดคำโดยยัติภังค์ แต่จะเลือกตัดบรรทัดที่โหนดระยะช่องไฟหรือโหนดจุดเลือกตัดคำโดยไม่ใช้ยัติภังค์เท่านั้น เนื่องจากโหนดทั้งสองชนิดมีแต้ม penalty เป็นศูนย์

ผู้ใช้งานสามารถกำหนดโหนดจุดเลือกตัดคำในเอกสารเองได้โดยใช้คำสั่ง \- เช่น “แฮ\-ฉล\-โท\-เฉียน” จุดตัดคำที่ผู้ใช้กำหนดเองนี้จะไม่ได้มีค่า penalty เท่ากับ hyphenpenalty แต่จะใช้ค่า exhyphenpenalty แทน (ย่อมาจาก explicit hyphenpenalty หรือแปลว่า hyphenpenalty แบบชัดแจ้ง) มีค่าปริยายเป็น 50 ซึ่งน้อยกว่าค่าปกติของ hyphenpenalty ผู้ใช้งานสามารถบังคับให้ TEX ตัดคำที่จุดที่ผู้ใช้งานเลือกเองได้โดยตั้งค่า exhyphenpenalty เป็น -10000

TEX จะคำนวณแต้มเสียจากองค์ประกอบอื่น ๆ ด้วย

- เพื่อที่จะกันไม่ให้หนึ่งย่อหน้าใช้จำนวนบรรทัดเกินกว่าที่จำเป็น TEX บวกแต้ม linepenalty สำหรับทุก ๆ บรรทัดที่ใช้ในย่อหน้า มีค่าโดยปริยายเป็น 10

- ถ้าบรรทัดที่ติดกันมีแต้ม badness ห่างกันมาก เช่น บรรทัดบนยืดโหนดระยะช่องไฟเยอะ แต่บรรทัดล่างไม่ยืดเลย หรือหด TEX ก็จะเพิ่ม adjdemerits เข้าแต้มเสีย

- ถ้าบรรทัดที่อยู่ติดกันมียัติภังค์ทั้งสองบรรทัด ก็จะเพิ่มแต้ม doublehyphendemerits เข้าแต้มเสีย

- ถ้าบรรทัดที่อยู่ก่อนจบย่อหน้าเลือกจุดตัดบรรทัดที่โหนดเลือกตัดคำด้วยยัติภังค์ จะเพิ่มแต้ม finalhyphendemerits เข้าแต้มเสีย

สามารถหาข้อมูลเรื่องการคำนวณแต้มเสียจากแต้มต่าง ๆ ได้จากหนังสือ TEX *by topic, a* TEX*nician's reference* บทที่ 19 เรื่องการตัดบรรทัด (Eijkhout, 1991/2007)

ขั้นตอนวิธี Knuth–Plass จะพยายามทำให้แต้มเสียน้อยที่สุด ซึ่งจะอธิบายพฤติกรรมประหลาด ๆ ในบางครั้งของ TEX นั่นคือถ้าผู้ใช้งานตั้งค่าแต้มหนึ่งเยอะเกินไป TEX อาจยอมทำอย่างอื่นเพื่อให้ได้แต้มเสียที่น้อยลง เช่น ถ้าผู้ใช้งานตั้ง `interword-stretch` ไว้ต่ำ แต่พอดูเอกสารที่ได้อาจมีบางบรรทัดที่ยืดมากกว่า `interword-stretch` อาจเกิดจากผู้ใช้งานตั้ง `hyphenpenalty` มากเกินไป ทำให้แต้มเสียของย่อหน้าจากการยืดโหนดระยะช่องไฟเกินความสามารถการยืดนั้นน้อยกว่าแต่เสียจากการเลือกโหนดจุดเลือกตัดคำ สามารถแก้ได้โดยการตั้งแต้ม `hyphenpenalty` ให้ต่ำกว่าเดิม

สำหรับการสร้างเอกสารภาษาไทย พบว่า

```
\hyphenpenalty=500
\doublehyphendemerits=1000
\finalhyphendemerits=2500
```

จะทำให้เอกสารสวยงามที่สุด

แม้ TEX จะมีขั้นตอนวิธีตัดบรรทัดที่ละเอียดอ่อนและให้ผลดีที่สุดในบรรดาขั้นตอนการตัดบรรทัดทั้งหมด แต่เนื่องจาก TEX นั้นออกแบบมาสำหรับภาษาอังกฤษ[3] TEX จึงไม่รู้วิธีหาตำแหน่งใส่โหนดจุดเลือกตัดคำในประโยคภาษาไทยด้วยซ้ำ ก่อนหน้านี้ คุณเทพพิทักษ์ การุญบุญญานันท์ (NECTEC) ได้นำขั้นตอนวิธีหาตำแหน่งแยกคำด้วยยัติภังค์ของ TEX นั่นคือขั้นตอนวิธี Knuth–Liang (Liang, 1983) มาปรับใช้กับภาษาไทยผ่านชุดคำสั่ง `utf8-hyph` (TEX Users Group, 2023) ซึ่งต่อมาได้นำไปใช้ในชุดคำสั่ง `polyglossia` และ `babel` ด้วย อย่างไรก็ตาม วิธีดังกล่าวมีข้อจำกัด เนื่องจากขั้นตอนวิธี Knuth–Liang ไม่ได้ใช้พจนานุกรมคำไทย แต่ใช้วิธีการจับรูปแบบการแยกคำ (hyphenation pattern) ซ้อนกันเพื่อดูว่าตำแหน่งไหนควรใส่ยัติภังค์หรือไม่ ในภายหลัง คู่มือการใช้งานของ `babel` ถึงขั้นระบุว่าภาษาไทย*ไม่ใช้ยัติภังค์เพื่อการแยกคำ*ด้วยซ้ำ (Bezos, n.d.) ซึ่งไม่ตรงกับกฎการใช้ยัติภังค์ของราชบัณฑิต

[3] TEX เริ่มรองรับภาษาอื่น ๆ ในปี 1989 โดยชุดคำสั่ง `babel` ซึ่งมาหลัง TEX 12 ปี และเริ่มรองรับภาษาไทยในปี 2013

ทางผู้พัฒนาชุดคำสั่งตระหนักดีว่าการหาตำแหน่งตัดคำของภาษาไทยนั้นเป็นเรื่องที่ท้าทาย และเป็นโจทย์ที่สำคัญในวงการประมวลผลภาษาธรรมชาติมานานแล้ว (Natural Language Processing – NLP) ผู้พัฒนาชุดคำสั่งจึงขอแสดงความขอบคุณอย่างสูงต่อทีมงาน PyThaiNLP ที่ได้เปิดเครื่องมือประมวลผลภาษาไทยต่าง ๆ แก่สาธารณะภายใต้สัญญาอนุญาตใช้ Apache 2.0 รวมถึงขั้นตอนวิธี `newmm` ด้วย ซึ่งเปิดให้ผู้สนใจนำโปรแกรมไปใช้ แก้ไขดัดแปลงได้โดยอิสระ ซึ่งนำมาสู่ชุดคำสั่งนี้ ที่แปลขั้นตอนวิธี `newmm` จากภาษา Python เป็นภาษา Lua แล้วนำไปเชื่อมกับ LuaLaTeX เพื่อตัดคำภาษาไทยได้ในที่สุด

ในบทถัดไป จะกล่าวถึงกระบวนการเชื่อม LuaLaTeX กับ `newmm` และจะอธิบายชุดคำสั่งที่อยู่เบื้องหลังการทำงานของชุดคำสั่งนี้ทั้งหมด

บทที่ 3

การเชื่อม LuaLaTeX กับ newmm

สามารถหาข้อมูลเพิ่มเติมเกี่ยวกับการทำงานของ LuaTeX (ไม่ใช่ LuaLaTeX) ได้จาก LuaTeX *Reference Manual* (LuaTeX development team, 2025)

§ 3.1 | ระบบคอลแบ็ก

§ 3.2 | ระบบแคช

บทที่ A

การใช้ปัญญาประดิษฐ์ในกระบวนการพัฒนา

ผู้พัฒนาชุดคำสั่งได้พัฒนาส่วนต่อประสานระหว่าง LuaLaTeX และขั้นตอนวิธี `newmm` เอง ได้เขียนคู่มือการใช้งานทั้งภาษาไทยและภาษาอังกฤษเอง แต่ใช้ Claude Opus 5.5 เพื่อช่วยแปลขั้นตอนวิธี `newmm` จากโปรแกรม `PyThaiNLP` ให้เป็นภาษา Lua และได้ใช้เพื่อ

แก้ไวยากรณ์ภาษาอังกฤษ

บรรณานุกรม

Bezos, J. (n.d.). *Babel locale guides – Thai*. The LaTeX Project. Retrieved November 5, 2026, from https://latex3.github.io/babel/guides/locale-thai.html

Braams L., J. (2026, October 29). *Babel user guide: Localization and internationalization* (J. Bezos, Cont.). Version 26.15.

Chaovavanich, K. (2026, October 7). *PyThaiNLP: newmm algorithm implementation* [The algorithm based on notebook by Chaovavanich, Korakot. Others in the PyThaiNLP team also contributed to the algorithm]. Retrieved November 3, 2026, from https://github.com/PyThaiNLP/pythainlp/blob/main/pythainlp/tokenize/newmm.py

Charette, F., Reutenauer, A., Fogiel, U., Roucariès, & Spitzmüller, J. (2026, September 11). *Polyglossia: Modern multilingual typesetting with XeLaTeX and LuaLaTeX*. Version 2.13. Retrieved November 2, 2026, from https://texdoc.org/serve/polyglossia/0

Eijkhout, V. (2007, October 2). *TeX by topic, a TeXnician's reference* [Book was originally printed in 1991 by Addison-Wesley UK. The pdf version was made available in 2001, and appeared on CTAN in 2007]. Retrieved November 4, 2026, from https://ctan.org/pkg/texbytopic?lang=en (Original work published 1991)

Git Installation. (2026) (2.56.0). Retrieved November 3, 2026, from https://git-scm.com/install/linux

Knuth, D. E. (2021, February). *The TeXbook* (35th Jubilee Edition). Addison-Wesley. (Original work published 1984)

Knuth, D. E., & Plass, M. F. (1984). Breaking paragraphs into lines. *Software – Practice and Experience*, *11*, 1119–1184. https://gwern.net/doc/design/typography/tex/1981-knuth.pdf

Liang, F. M. (1983, August). *Word Hy-phen-na-tion by Com-pu-ter* [Ph.D. thesis]. Standford University.

LuaTeX development team. (2025, December 12). *LuaTeX Reference Manual*. Version December 12, 2025. LuaTeX development team. Retrieved November 5, 2026, from https://texdoc.org/serve/luatex/0

Phattiyaphaibun, W., Chaovavanich, K., Polpanumas, C., Suriyawongkul, A., Lowphansirikul, L., Chormai, P., Limkonchotiwat, P., Suntorntip, T., & Udomcharoenchaikit, C. (2023). *PyThaiNLP: Thai Natural Language Processing in Python*.

Robertson, W. (2026, August 11). *The fontspec package* (P. Gesand, J. Wright et al., Collab.). Version 2.9h. Retrieved November 2, 2026, from https://texdoc.org/serve/fontspec/0

TEX Users Group. (2023, July 3). *TEX hyphenation patterns*. TEX Users Group. Retrieved November 5, 2026, from https://www.hyphenation.org

สำนักงานราชบัณฑิตยสภา. (2023). *หลักเกณฑ์การใช้เครื่องหมายวรรคตอน – ยัติภังค์*. สำนักงานราชบัณฑิตยสภา. Retrieved November 4, 2026, from https://www.orst.go.th/iwfm_table.asp?a=36&i=0040002104011001%2F63erk0249069